



廖介任

資深AI工程師

大語言模型

RAG系統

模型微調

語音AI

Python

新加坡商楓葉資訊科技有限公司台灣分公司 | 資深大語言模型應用程式工程師

國立臺灣師範大學 | 資訊工程博士班 博士日間就讀中

新北市汐止區 | 19~20年工作經歷 | 希望職稱：資深大語言模型應用開發工程師

我擁有超過17年的軟體開發經驗，近年專注於大語言模型（LLM）應用開發、RAG系統架構、模型微調與壓縮。我具備從研究論文復現到產品落地的完整能力，擅長將AI技術轉化為可交付的企業級解決方案。目前為國立臺灣師範大學資訊工程博士班在讀，研究方向為語音AI。

個人資料 男、48歲、免役
就業狀態 待業中
主要手機 0958-846-585
E-mail xrickliao@gmail.com
通訊地址 新北市汐止區新台5***
英文姓名 Rick Liao
聯絡方式 手機聯絡
駕駛執照 普通小型車駕照
交通工具 普通小型車

學歷

國立臺灣師範大學

2018/9~2027/6

資訊工程博士班 | 博士日間就讀中

工作經驗

總年資 19~20年工作經歷

新

資深大語言模型應用程式工程師

2025/2~2026/3

新加坡商楓葉資訊科技有限公司台灣分公司（電腦及其週邊設備製造業 30~100人）

1年2個月

助理工程師 | 新北市汐止區

負責LLM模型微調與RAG應用開發，主導多項AI產品從零到一落地。包括LoRA微調DeepSeek-R1:7B模型，提升搜尋準確率約2%。開發多款企業級RAG系統，列表如下：

- DQE RAG：提升設計缺陷發現效率10%~15%。
- SalesAI：提升產品資訊搜尋效率30%~40%。
- DocAI：支援多格式智慧文件問答系統並具跨機器知識共享功能。
- TeacherAssist：從文字自動生成PPTX簡報。

#LLM #生成式AI #提示工程 #RAG #AI 代理人 #AI輔助程式設計-Claude Code

聯	資深AI工程師 聯億通股份有限公司（其它軟體及網路相關業 1~30人） 助理工程師 台北市內湖區	2023/9~2024/9 1年1個月
開發線上客戶問答Web應用，利用LLM分析語音內容提升客戶需求理解。開發資源極度受限的聲音事件分類模型，準確度達96.8%，模型大小從18.9MB壓縮至70KB以下。採用Microsoft FLAML框架開發AutoML系統，管理模型訓練流程及資料處理自動化。		
台	數位語音及音訊演算法工程師 台灣歌爾泰克有限公司（其他電子零組件相關業 30~100人） 助理工程師 台北市內湖區	2019/12~2022/3 2年4個月
開發麥克風晶片用深度學習VAD及Voice Command模型，辨識率達96%，壓縮率超過80%。開發散熱風扇異音檢測模型（Time-Domain + One-Class SVM，Raspberry Pi Zero）。使用Python/FastAPI/Matplotlib開發語音頻譜分析Web應用。		
	NLP暨深度學習技術副理 威剛科技股份有限公司（電腦及其週邊設備製造業 500人以上） 演算法工程師 台北市內湖區	2017/12~2018/12 1年1個月
建構6人深度學習團隊，開發Rule-Based與機器學習聊天機器人引擎，建構初版Kaldi ASR系統。		
臻	程式設計師 臻豐碩科技有限公司 Internet程式設計師 桃園市八德區	2012/9~2017/3 4年7個月
開發C# .NET WinForm及ASP.NET Web應用，服務中科院專案。		
Z	iOS程式設計師 Zoaks有限公司 iOS工程師	2009/3~2011/9 2年7個月
開發iOS行銷App，包括可口可樂125週年、佳麗寶美研誌、FamilyMart初版。		
宜	軟體開發組組長 宜蘭縣教育處資訊網路中心 編輯	2000/7~2009/7 9年1個月
帶領團隊開發縣府行政系統、校務行政系統（三層架構，同時上線5000人）及多項Web應用。		

求職條件

希望性質 全職工作
上班時段 日班、可配合輪班
可上班日 錄取後隨時可上班
希望待遇 面議
希望地點 新北市、台北市、新加坡
遠端工作 對遠端工作有意願

希望職稱 資深大語言模型應用開發工程師
希望職類 AI工程師

工作內容 負責大語言模型微調與優化、RAG系統架構設計與開發、AI產品從零到一的落地實施，並將AI技術轉化為企業級解決方案。

自傳

我從2000年開始軟體開發生涯，歷經多家企業與不同領域的技術挑戰，累積了豐富的軟體與AI技術經驗。近年來，我專注於大語言模型與語音AI的研究與應用，致力於將前沿技術轉化為實際可用的產品與解決方案。我熱愛技術創新與團隊合作，持續在國立台灣師範大學深造，追求更高的專業成就。

資格認證

更多資格認證

Udacity深度學習納米學位, Coursera史丹佛機器學習課程, TOEFL 90分, GRE 301分

專長

大語言模型應用開發

擅長RAG系統架構、AI Agent、LangChain、Prompt Engineering及向量資料庫(FAISS/Milvus/Qdrant)的應用開發。

模型微調與優化

熟悉LoRA、QLoRA、PEFT、DPO、Prompt-Tuning技術，具備量化、剪枝及知識蒸餾經驗。

語音AI技術

具備ASR (Kaldi / E2E)、語音增強、VAD / KWS、發音評估(MDD/APA/GOP)等技術能力。

軟體開發技術

精通Python、PyTorch、HuggingFace、FastAPI、React、Next.js、Rust及C++。

語言能力

英文

聽/中等 | 說/中等 | 讀/中等 | 寫/中等

中文

聽/中等 | 說/中等 | 讀/中等 | 寫/中等

KnowledgeLM: Knowledge-Based Retrieval-Augmented Generation System

Version: 2.0 (2026-01-15)
Concept: Your Personal Librarian for Knowledge Domains

KnowledgeLM is a robust, local RAG (Retrieval-Augmented Generation) system designed to ingest, index, and answer questions from your documents. It functions as a "personal librarian" that not only knows where every book is stored but can also read, understand, and synthesize answers based on curated knowledge domains.

Overview

KnowledgeLM implements a Knowledge-Based RAG Architecture, focusing on curated "Skills" (Knowledge Domains) that combine multiple source files for precise, domain-specific Q&A.

Key Features

- Local Processing: Powered by local LLMs (Ollama) and OpenAI integration.
- Skill-Based Knowledge: Organize documents into logical Skills (Knowledge Domains).
- Four-Database Architecture: SQLite + FAISS + MongoDB + Redis for optimal performance.
- Smart Ingestion Pipeline:
 - Automatic PDF text extraction (PyPDF2).
 - Smart chunking (~1000 chars with overlap).
 - High-dimensional embeddings using BAAI/bge-m3 (1024-dim).
- Architecture Patterns:
 - Single Source of Truth: skill_heads table eliminates sync issues.
 - Hybrid Data Models: TypedDict for performance, Pydantic for validation.\

Project Structure

```
KnowledgeLM/
├── app/
│   ├── api/v1/endpoints/ # FastAPI route handlers
│   ├── models/          # Pydantic & TypedDict definitions
│   ├── Providers/        # Infrastructure layer (DB, Vector, LLM)
│   └── KnowledgeLMServices/ # Business logic (Knowledge-based RAG)
├── data/
│   ├── faiss_indices/    # Physical FAISS vector stores
│   │   └── skills/       # Skill-specific indices
│   ├── files/           # Raw PDF sources
│   └── knowledge_metadata.db # SQLite knowledge architecture
├── scripts/
│   └── init_docai_windows.py # Database initialization script
└── template/            # HTML/Jinja2 templates
```

專案概述

此專案旨在開發一個高效能且極度輕量化的深度學習模型，用於在資源受限的邊緣裝置上進行聲音事件分類，特別是針對警報聲的偵測。我們專注於模型壓縮與優化，以實現卓越的準確度，同時大幅縮減模型大小，使其適用於嵌入式系統和微控制器。

特色

- 極致輕量化模型: 將原始 18.9MB 的模型成功壓縮至 100KB 以下，大幅降低記憶體和儲存空間需求。
- 高準確度: 在聲音事件分類任務中實現 96.8% 的準確度。
- 邊緣裝置優化: 專為資源受限的硬體設計，確保模型在低功耗環境下高效運行。
- 警報偵測專用: 針對警報聲音事件進行優化，提供可靠的即時偵測能力。
- 端到端解決方案: 提供從模型訓練、優化到部署的完整流程。

模型效能摘要

指標值模型大小< 100KB準確度96.8%原始模型大小18.9MB

專案結構

uec-ai-dev/

```
|— Doc/          # 專案文件與報告
|— Libs/         # 共享庫與工具，包含音訊處理、量化等
|  |— SmartMic_SharedLibs/
|  |— wav2carray_codes/
|  |— datetime_util.py
|  |— int16_to_int8.c
|  |— quantization_util.py
|  |— simple_quant.cc
|— Final_Models/  # 最終優化並導出的模型
|  |— only_alarm/
|  |— Pruning_Ratio_0.6_0.85_20240221/
|  |— acdnet_model_0.6_0.85pruning_95.4.cc
|— notes/        # 開發筆記與實驗紀錄
|  |— retrain_after_two_stages_pruning/
|— pysrc/        # Python 原始碼，主要用於訓練與資料處理
|— src/          # 核心程式碼，包含模型定義、訓練、部署相關
|  |— SharedLibs/  # 共享函式庫，如音訊處理、系統工具
|  |— Training/    # 模型訓練相關程式碼 (單折、交叉驗證)
|  |  |— CV_Training/
|  |  |— Single_Fold/
|  |  |— unused_codes/
|  |— common/      # 通用工具與資料準備
|  |— deployment/  # 模型部署相關工具與結果分析
|  |— mcu_codes/    # MCU 嵌入式程式碼範本與模型整合
|  |— model_convert/  # 模型轉換 Jupyter Notebooks (PyTorch to TFLite)
|  |— old_ipynbs/   # 舊版 Jupyter Notebooks
|  |— th/          # PyTorch 模型定義與資源
|  |— uec_aed/      # 警報事件偵測相關程式碼 (C/C++ 實現)
|— trained_models/  # 訓練好的模型，包括中間產物和 C 模型
|  |— step_7_Generate_C_Models/
|— unittest/      # 單元測試相關
|— README.md      # 本檔案
```



Coursera.jpeg

Coursera Machine Learning Certificate



udacityDL.jpg

Udacity Deep Learning Nano Degree

Chieh-Ren Liao National Taiwan Normal University, Taipei, Taiwan 80747002s@ntnu.edu.tw	Berlin Chen National Taiwan Normal University, Taipei, Taiwan berlin@ntnu.edu.tw
摘要 發音品質評估中的發音好壞度 (Goodness of Pronunciation, GOP) 分數，是電腦輔助語言學習的關鍵技術。近期的研究指出，直接使用聲學模型原始輸出 logits 來計算 GOP 分數，其表現優於傳統基於 softmax 機率的方法。因為 logits 避免了機率飽和問題並保留了更豐富的區分性資訊。然而，現有的 logit-based 方法大多僅依賴最大值、均值或變異數等基本統計量，這忽略了在音素持續時間內，logit 序列更為複雜的動態分佈與時序特性。為了更全面地捕捉 logit 序列中所蘊含的發音細節，本研究提出了一套多面向的統計分析法。我們探索了五種能夠描述 logit 序列不同特性的高階統計指標：(1) 動差生成函數，用以計算分佈的偏度 (skewness) 與峰度 (kurtosis)；(2) 資訊理論，透過計算熵 (entropy) 來量化模型的不確定性；(3) 高斯混合模型 (GMM)，用以擬合 logit 的多模態分佈；(4) 時間序列分析，計算自相關係數 (autocorrelation) 來衡量 logit 的穩定性；以及 (5) 極值理論，採用 top-k 平均來獲得更穩健的峰度估計值。	線方法 ($GOP_{MaxLogit}$, GOP_{margin}) 進行效能比較。初步結果顯示，部分高階統計指標，特別是那些能夠描述 logit 序列穩定性和分佈形狀的特徵，在發音錯誤檢測的分類任務上展現出更高的準確性，並與人類專家評分呈現出更強的相關性。這項研究證明，對 logit 序列進行更深層次的統計建模，是提升自動化發音評估系統效能的一個有效途徑。 Abstract The Goodness of Pronunciation (GOP) score for pronunciation quality assessment is a key technology in computer-assisted language learning. Recent studies have shown that computing GOP scores directly from the acoustic model's raw output logits outperforms traditional softmax-probability-based methods, because logits avoid probability saturation issues and retain richer discriminative information. However, existing logit-based methods mostly rely on basic statistics such as maxima, means, or variances, which neglect the more complex dynamic distributions and temporal characteristics of logit sequences over phoneme durations. To more comprehensively capture pronunciation details embedded in logit sequences, this study proposes a multi-faceted statistical analysis method. We explore five higher-order statistical indicators that describe different characteristics of logit

my_publication_rocling2025.pdf

2025 Rocling Publication:A Multi-faceted Statistical Analysis for Logit-based