

RAGTruth 論文深入解析與實驗整理

*A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models
(ACL 2024)*

一、論文的研究動機來源

【開卷考試的盲點】 想像大語言模型（LLM）是一位記憶力超強但偶爾會胡言亂語的學生。為了防止他在考試中胡亂發揮，我們採用了 RAG（檢索增強生成）技術，相當於在考試時發給他一張「參考資料提示卡」（開卷考試），要求他『嚴格根據提示卡回答』。

儘管有了參考資料提示卡，研究團隊發現了現有技術與實際應用中的三大核心痛點：

- 開卷依然會抄錯或亂寫：**即便手握參考資料，大模型依然會產生與資料相矛盾、或憑空捏造資料中沒有的內容。在醫療診斷、法律諮詢或新聞摘要等嚴肅場景中，這種「看起來很有道理的胡說八道」會造成嚴重後果。
- 缺乏真實且高質量的 RAG 幻覺資料集：**要解決幻覺，必須先有精準的「標籤數據」來訓練與評估檢測器。但現有的幻覺資料集大多是「人工刻意誘發」（合成數據，不自然）或「規模過小」，且沒有專門針對 RAG 架構進行字詞級（Word/Span-level）的細粒度標註。
- 研究團隊的核心目標：**打造一個大規模、源自真實應用場景、經過專家細粒度標註的 RAG 幻覺基準資料集（RAGTruth），並探討如何利用這些數據訓練輕量化模型來精準抓出並抑制幻覺。

二、論文內容分段拆解

第 1 章：緒論（Introduction）

闡述 RAG 技術的普及與限制，揭示大模型在 RAG 下仍會產生幻覺的現狀，並提出 RAGTruth 資料集及其四大核心貢獻。

第 2 章：相關工作（Related Work）

回顧大模型幻覺的定義、現有幻覺評估資料集的局限性（如 HaluEval, FELM），以及目前主流的幻覺檢測方法（不確定性評估、外部知識對比、LLM 自查等）。

第 3 章：RAGTruth 的建構流程（Construction Process）

詳細介紹資料集的建構管線（Data Pipeline）：定義 4 種幻覺分類法、選擇 3 種典型任務（QA、數據轉文本、新聞摘要）、使用 6 種主流 LLM 生成回答，並由專家進行字詞級標註與品質控管。

第 4 章：幻覺基準分析（Hallucination Benchmark Analysis）

從任務類型、模型規模、回答長度、幻覺發生的文本位置（熱圖）等多個維度，深度剖析幻覺發生的規律與統計特徵。

第 5 章：實驗設定（Experimental Setup）

設定評估基準，比較 Prompt-based 方法（GPT-4/GPT-3.5）、SelfCheckGPT、LMvLM 以及利用 RAGTruth 訓練集微調的 Llama-2-13B 模型在回答級（Response-level）與片段級（Span-level）的檢測能力。

第 6 章：實驗結果與幻覺抑制（Experimental Results & Suppression）

展現各算法的檢測成績，證明微調小模型（Llama-2-13B）能超越 GPT-4；同時展示利用該檢測器進行回答過濾，能顯著降低模型的幻覺率。

第 7-9 章：總結、局限性與倫理（Conclusion & Limitations）

總結研究成果，指出跨領域泛化能力與合成數據結合等未來研究方向。

三、核心數學方程式與指標深入拆解

論文中提出了三項核心量化指標與數學函數，用以精確測量幻覺強度、評估檢測器效能，以及驅動模型微調。以下採用比喻法進行一步步拆解：

1. 幻覺密度公式 (Hallucination Density)

【概念與目的比喻】 想像你在檢查「一籃水果裡的壞蘋果」。如果籃子很大（回答很長），裡面有 5 個壞蘋果；另一個小籃子只有 10 個水果，裡面也有 5 個壞蘋果。我們不能只看壞蘋果的絕對數量，而是要看「每 100 個水果裡有幾個壞蘋果」。其目的在於標準化不同模型生成長短不一回答時的「幻覺濃度」，實現公平比較。

變數意義與表示法說明：

- **N_span** (幻覺片段總數) Count of Hallucinated Spans。代表專家審查後劃出的獨立幻覺區塊數量。從人工標註的 Span 標籤計數而來。
- **W_total** (生成的總字數) Total Word Count。代表模型輸出回答中的總詞數 (Word/Token Count)。從文本分詞 (Tokenization) 長度計算而來。
- **× 100** (放大係數) 將原始比例轉換為「每 100 個字詞的單位密度」，方便直觀閱讀與統計。

從最小運算逐步疊加至完整方程式：

步驟一（基礎計數）：統計標註出來的幻覺區塊總數 N_{span} 與生成回答總字數 W_{total} 。

步驟二（單字平均比率）：執行除法 N_{span} / W_{total} ，算出平均每個字詞包含多少個幻覺片段。

步驟三（完整方程式）：乘以 100 進行比例放大： $Hallucination\ Density = (N_{span} / W_{total}) \times 100$

這項數學式在研究中的角色：

它是比較 GPT-4、Llama-2、Mistral 等不同模型在各種任務中「產生幻覺的頻率與嚴重程度」的核心量化指標。

2. 字元級涵蓋率與準確率指標 (Span-level Precision, Recall, F1 Score)

【概念與目的比喻】 想像「警犬搜尋毒品藏匿區域」。專家標註了真正的毒品範圍 (S_{gt})，而 AI 檢測器圈出了警報範圍 (S_{pred})。Precision (精準度) 代表警犬圈出的區域裡，真正有毒品的比例 (你有沒有亂報警、過度敏感?)；Recall (召回率) 代表真正

的毒品區域中，被警犬成功抓到的比例（你有沒有漏查？）；F1 Score 則是綜合考量「不亂報」與「不漏抓」的調和平均成績。

變數意義與表示法說明：

- S_{gt} （真實標籤集合） Ground-Truth Character Set。專家標註的所有幻覺字元位置集合。
- S_{pred} （預測標籤集合） Predicted Character Set。AI 檢測算法圈出的所有預測幻覺字元位置集合。
- $|S_{pred} \cap S_{gt}|$ （交集大小）代表兩者重疊的字元數量，即 AI 猜對且確實是幻覺的字元個數。
- $|S_{pred}|$ 與 $|S_{gt}|$ 分別代表 AI 預測總字元數與真實幻覺總字元數。

從最小運算逐步疊加至完整方程式：

步驟一（集合交集）：計算重疊字元數 $|S_{pred} \cap S_{gt}|$ 。

步驟二（計算精準度 Precision, P）： $P = |S_{pred} \cap S_{gt}| / |S_{pred}|$

步驟三（計算召回率 Recall, R）： $R = |S_{pred} \cap S_{gt}| / |S_{gt}|$

步驟四（完整方程式：調和平均 F1 Score）： $F1 = 2 \times (P \times R) / (P + R)$

這項數學式在研究中的角色：

這套字元級（Char-level / Span-level）測量公式，是用來檢驗檢測算法是否具備「細粒度（Fine-grained）精準定位幻覺位置能力」的關鍵考題。

3. 微調檢測器之交叉熵損失函數（Supervised Cross-Entropy Loss）

【概念與目的比喻】想像成「打靶訓練的懲罰得分」。訓練 Llama-2-13B 模型去預測每個字是不是幻覺。如果某個字明明是幻覺，模型卻很有自信地預測「不是幻覺」，系統就會給它一個極高的懲罰分數（Loss）。訓練的目的就是讓總懲罰分數越小越好，從而教導模型掌握判斷邊界。

變數意義與表示法說明：

- y_i (真實標籤) 第 i 個 Token 的真實標籤 ($y_i = 1$ 代表是幻覺, $y_i = 0$ 代表正常)。
- $P(w_i | C, R)$ (預測條件概率) 模型在給定上下文 C (Context) 與回答 R (Response) 下, 預測第 i 個位置為標籤 Token 的條件概率。
- $\log$ (對數函數) 將概率 (0~1) 映射為懲罰值, 預測概率越低 (越不自信或猜錯), 負對數懲罰越大。
- $\sum_{i=1}^N$ (全句累加) 代表對文本中所有 N 個 Token 的懲罰值進行加總。

從最小運算逐步疊加至完整方程式：

步驟一 (單字概率對數)：計算 $\log P(w_i | C, R)$ 。

步驟二 (單字加權懲罰)： $- [y_i \times \log P_i + (1 - y_i) \times \log (1 - P_i)]$ (只有對應的真實標籤會觸發懲罰)。

步驟三 (完整方程式：全句累加 Loss)： $\text{Loss} = - \sum_{i=1}^N [y_i \log P(w_i|C,R) + (1 - y_i) \log(1 - P(w_i|C,R))]$

這項數學式在研究中的角色：

這是將 Llama-2-13B 從「普通語言模型」改造訓練為「專門抓幻覺的裁判模型」時所依據的數學驅動引擎。

四、實驗步驟、方法與結果詳解

1. 實驗步驟與方法

步驟一：回應生成 (Response Generation)：選定 3 種任務 (QA、數據轉文本 Yelp JSON、新聞摘要 CNN/DM)，使用 6 個主流 LLM (GPT-3.5-turbo, GPT-4, Llama-2-7B/13B/70B, Mistral-7B-Instruct)，總共收集 17,790 個自然生成的回答。

步驟二：專家細粒度標註 (Human Annotation)：聘用專業標註員進行雙審標註 (一致率達 91.8%)，劃分出 4 種幻覺類型：顯著衝突、微妙衝突、顯著無根據資訊、微妙無根據資訊。

步驟三：檢測演算法對比（Hallucination Detection Baselines）：測試 4 種不同思路：
Prompt-based (GPT-3.5/GPT-4)、SelfCheckGPT（內部一致性）、LMvLM（多輪交叉質疑）
以及利用 RAGTruth 訓練集微調的 Llama-2-13B。

步驟四：幻覺抑制應用（Hallucination Suppression）：利用訓練好的檢測器進行多候選回答
採樣過濾，自動選擇最乾淨的回答輸出。

2. 實驗結果與對比數據

下表呈現了各檢測算法在 RAGTruth 測試集上的詳細效能對比：

檢測方法 / 模型	回答級 F1 (Response)	片段級 F1 (Span)	片段級 精準度 (Precision)
Prompt (GPT-3.5-turbo)	52.9%	12.8%	7.8%
Prompt (GPT-4-turbo)	63.4%	28.3%	18.4%
SelfCheckGPT (GPT-3.5)	58.8%	-	-
Finetuned Llama-2-13B (本研究)	78.7%	52.7%	55.6%

key 實驗發現總結：

- GPT-4 單靠 Prompt 檢測能力有限：即使是 GPT-4，在未經過專門微調的情況下，片段級精準度僅有 18.4%，存在嚴重的過度標註與誤報問題。
- 微調小模型展現驚人優勢：利用 RAGTruth 資料集微調的 Llama-2-13B，不論在回答級（F1 78.7%）還是片段級（F1 52.7%），表現均大幅超越 GPT-4。
- 任務間幻覺率差異極大：數據轉文本（Data-to-Text）任務幻覺率高達 68.6%，主因是大模型對於 JSON 中的 null 欄位或時間屬性理解混亂。

- **幻覺抑制效果顯著**：透過微調檢測器進行回答採樣過濾，可使開源模型（如 Llama-2, Mistral）的幻覺率大幅下降 63.2%，GPT-4 的幻覺率也能再降低 51.0%。

五、論文總結與核心問答

1. 論文總結

RAGTruth 是第一個專門針對 RAG（檢索增強生成）架構所打造的大規模、自然生成、字詞級標註的幻覺基準資料集。它揭示了「開卷考試下大模型依然廣泛存在幻覺」的現狀，並證明了「不需要盲目追求昂貴的 GPT-4，只要擁有高質量的標註數據（RAGTruth），微調 13B 級別的小模型就能打造出世界頂尖的幻覺裁判與過濾器」。

2. 透視論文核心的 4 個關鍵問題

Q1：為什麼即便使用了 RAG（檢索增強生成），大語言模型依然會產生幻覺？RAGTruth 解決了什麼痛點？

解答：RAG 雖然提供了外部參考資料，但 LLM 內部的預訓練記憶、對複雜格式（如 JSON）的理解偏差、以及長文本生成的尾端注意力衰減，都會導致模型「講出資料沒寫的事」或「曲解資料內容」。RAGTruth 解決了過去缺乏真實自然生成、高質量、字詞級細粒度標註的 RAG 幻覺數據痛點，為 AI 社群提供了標準訓練與測試基準。

Q2：RAGTruth 將 RAG 架構下的幻覺分為哪四種類型？哪一種最常發生？

解答：分為「顯著衝突」、「微妙衝突」、「顯著無根據資訊」與「微妙無根據資訊」四類。統計顯示，「無根據資訊（Baseless Info）」的發生頻率遠高於「直接衝突（Conflict）」，即模型更容易憑空捏造資料中沒有的細節，而不是直接反駁資料。

Q3：為什麼微調後的 13B 小模型（Llama-2-13B）在幻覺檢測上能超越 GPT-4？這給工業界帶來什麼啟示？

解答：通用大模型（如 GPT-4）雖然知識淵博，但未針對「嚴苛的 RAG 逐字對比與幻覺邊界」進行專項優化，容易產生過度敏感或評判標準不一的問題。透過 RAGTruth 高質量數據微調的小模型，學會了專一的「裁判邏輯」。這給工業界的啟示是：在特定安全防護任務上，「高質量專用數據 + 微調小模型」比「通用昂貴大模型 Prompt」更精準、更省成本且更高效。

Q4：如何利用這個幻覺檢測模型來實際「抑制」LLM 生成時的幻覺？效果如何？

解答：採用「雙重採樣 + 檢測過濾」策略——讓 LLM 針對同一個問題生成多份候選回答，再由微調好的檢測模型自動剔除包含幻覺片段的回答，選擇最乾淨的回答輸出。實驗證明，這種方法能讓開源模型的幻覺率降低 63.2%，即便是 GPT-4 也能再降低 51.0% 的幻覺。