

Conversation Quality、RAG 回覆品質與 Chat Ground Truth Measurement 研究對話紀錄

匯出日期：2026-09-22

內容範圍：本對話中使用者與 ChatGPT 可見的研究討論內容。系統提示、內部工具呼叫與隱藏推理不包含在內。

Turn 1 — User

幫我進行 conversation quality estimate 研究

Assistant (進度更新)

我會把「conversation quality estimate」先拆成幾個可研究、可落地的子問題：**整段對話品質評分、turn-level 品質估計、使用者滿意度/互動品質、語音層面的自然度與流暢度、以及 LLM-as-a-Judge 型評估**。我會同時整理近年的代表論文、常用資料集與指標，再幫你收斂成適合做研究题目的方向。

Assistant (研究整理)

目前文獻有一個很重要的結論：「**Conversation Quality Estimation**」其實不是單一、統一名稱的 task。它主要分散在 *User Satisfaction Estimation (USE)*、*Dialogue Quality Evaluation*、*Interaction Quality (IQ)*、以及 human-human 的 *Perceived Conversation Quality (PCQ)* 幾條研究線；這也意味著我們可以把它重新定義成一個比傳統 USE 更完整的研究問題。

Assistant

可以。以目前 2026 年的研究脈絡來看，我建議不要把 **Conversation Quality Estimation (CQE)** 只理解成「替一段對話打一個分數」，而是把它定義成一個 **multi-level、multi-dimensional、multimodal** 的品質估計問題。這樣會比傳統的 User Satisfaction Estimation 更有研究價值，而且可以自然接到 speech、LLM、multimodal conversation。

1. 我會怎麼定義 Conversation Quality Estimation

給定一段多輪對話：

$$D = \{(U_1, S_1), (U_2, S_2), \dots, (U_T, S_T)\}$$

如果是語音對話，再加入：

$$A_t = \text{audio features at turn } t$$

我們希望模型同時預測：

$$Q_t = \text{turn-level quality}$$

以及：

$$Q_D = \text{dialogue-level quality}$$

更進一步，不只是輸出單一分數，而是：

$$Q_D = [Q_{\text{coherence}}, Q_{\text{relevance}}, Q_{\text{engagement}}, Q_{\text{efficiency}}, Q_{\text{naturalness}}, Q_{\text{satisfaction}}]$$

這其實是目前研究逐漸靠攏的方向。早期 Interaction Quality / User Satisfaction 工作主要估計使用者滿意程度；後來 FED、USR、FineD-Eval 開始做多面向 dialogue evaluation；最新工作則加入 LLM reasoning、user preference、speech/audio signal 與 multimodal information。

來源：<https://www.sciencedirect.com/science/article/abs/pii/S0167639315000679>

2. 這個領域其實有四條研究線

研究方向	核心問題	常見輸入	輸出
User Satisfaction Estimation	使用者現在滿不滿意？	text、dialogue history、system log	satisfaction
Dialogue Quality Evaluation	系統回應/整段對話好不好？	transcript	coherence / relevance / overall
Interaction Quality	人機互動過程是否順暢？	dialogue features、ASR/NLU、turns	1-5 quality
Perceived Conversation Quality	整體「聊得好不好」？	audio + lexical + interaction	conversation quality

2015 年的 Interaction Quality 工作已經指出，可以在**任意對話時間點**估計 ongoing interaction quality，而且 IQ 和實際 User Satisfaction 有相當程度的相關。

來源：<https://www.sciencedirect.com/science/article/abs/pii/S0167639315000679>

2019–2020 年 Amazon 的一系列工作進一步把問題轉成 **turn-level + dialogue-level User Satisfaction Estimation**。其中 Response Quality annotation 與 explicit user rating 的相關約為 0.76，而加入 turn-level satisfaction 後，也能改善整段 dialogue satisfaction 的判斷。

來源：<https://arxiv.org/abs/1911.08567>

所以從研究角度，我認為比較好的 framing 是：

Conversation Quality Estimation = Dialogue semantics + Interaction dynamics + User state + Speech behavior

而不是單純 sentiment analysis。

3. Conversation Quality 到底由什麼組成？

我會把它拆成下面六個 latent dimensions。

Dimension	問題
Relevance	回答有沒有回到使用者真正的問題？
Coherence	前後 conversation 是否一致？
Context retention	是否記得之前講過的事情？
Interaction efficiency	是否過度反問、重複、繞圈？

Dimension	問題
Engagement / Rapport	對話是否自然、有互動感？
User satisfaction	使用者是否覺得這段互動成功？

但如果是 **spoken conversation**，我認為還缺非常重要的一層：

$$Q = f(\text{content}, \text{prosody}, \text{turn-taking}, \text{timing}, \text{emotion})$$

這也是我認為目前最值得切入的研究缺口。

4. 為什麼 Speech 很重要

2023 Interspeech 有一篇和你的問題非常接近：

Automatically Predicting Perceived Conversation Quality in a Pediatric Sample Enriched for Autism

它直接預測 **Perceived Conversation Quality**。

研究者比較：

Lexical

Acoustic

和

Lexical + Acoustic

最後 lexical + acoustic 達到 **68% accuracy**，高於單純 lexical 的 54% 與 acoustic 的約 62.7%。

來源：<https://pmc.ncbi.nlm.nih.gov/articles/PMC11270905/>

這件事情非常值得注意。

因為它證明：

Conversation quality 不完全存在文字內容裡。

聲音本身具有額外資訊。

5. Speech CQE 可以使用哪些 features

2026 CHI 的 **Beyond Words: Measuring User Experience through Speech Analysis in Voice User Interfaces**
更直接把 speech 當作 UX / satisfaction sensor。

它研究的 features 包括：

Category	Features
Prosody	F0 mean、F0 variance
Timing	pause duration、pause count

Category	Features
Speaking style	articulation rate
Voice quality	jitter、shimmer、HNR
Fluency	filled pauses、repair
Linguistic	utterance length
Context	mood、stress、audio quality

研究發現這些 speech features 能和 attractiveness、trust、satisfaction 產生關聯，而且可以用 ML 區分 positive / neutral / negative UX。

來源：<https://doi.org/10.1145/3772318.3791747>

這其實已經非常接近：

$$Speech \rightarrow ConversationQuality$$

6. Turn-taking 可能比 emotion 更重要

Conversation Quality 有一個常被低估的訊號：

turn-taking

例如：

interruptions

overlap

response latency

turn duration

speaker dominance

Human-human conversation 的研究甚至發現，turn-taking features 在 user satisfaction prediction 上可以比單純 lexical 或 prosodic features 更有效。

來源：https://www.researchgate.net/publication/306494541_Predicting_User_Satisfaction_from_Turn-Taking_in_Spoken_Conversations

Perceived Conversation Quality 的另一項研究也發現，高品質 conversation 往往和較均衡的 speaking turns、較少 interruption、較佳 synchronization 有關。

來源：<https://arxiv.org/abs/2207.05791>

所以我會特別把 CQE 寫成：

$$CQ = f(Semantic, Acoustic, TurnTaking, Temporal)$$

而不是：

$$CQ = f(Text)$$

7. Text-based CQE 的重要基線

如果你要開始實驗，我認為至少需要理解這幾代方法。

Year	Work	意義
2015	Interaction Quality	ongoing quality estimation
2019	Multi-domain CQE via USE	turn-level satisfaction
2020	USR	reference-free dialogue evaluation
2020	FED	fine-grained dialogue quality
2020	Joint Turn/Dialogue USE	hierarchical estimation
2021	Turn-level Satisfaction RL	session label → turn score
2022	FineD-Eval	multi-dimensional dialogue evaluation
2024	CAUSE	counterfactual dissatisfied dialogues
2025	PRAISE	LLM-guided interpretable USE
2025	CMT-Eval	Chinese multi-turn evaluation
2026	speech UX / multimodal CQ	speech-informed quality

USR 是一個很重要的分水嶺：它不需要 reference response，而且可以輸出可解釋的 dialogue qualities，在 TopicalChat 和 PersonaChat 上與 human judgement 有明顯相關。

來源：<https://aclanthology.org/2020.acl-main.64/>

FED 則建立了含有 **18 種 fine-grained dialogue qualities** 的評估方式，可同時做 turn-level 與 conversation-level evaluation。

來源：<https://aclanthology.org/2020.sigdial-1.28/>

FineD-Eval 再往前一步，把 evaluation 明確變成 **multi-dimensional dialogue-level evaluation**。

來源：<https://aclanthology.org/2022.emnlp-main.220/>

8. 2024–2026 最大的變化：LLM 進入 evaluator


2025 NAACL 的 **PRAISE** 很值得讀。

它的思路不是直接問：

這個 user 滿不滿意？

而是先由 LLM 產生判斷 satisfaction 所需要的 **strategies / criteria**，再從 dialogue 中找出相關 evidence，最後做 satisfaction prediction。

也就是：




而且正式 inference 時不必持續使用 LLM，因此兼顧 interpretability 和 deployment cost。

來源：<https://aclanthology.org/2025.naacl-long.523/>


這個思想非常值得延伸到 CQE。

9. 我認為值得研究的模型架構

如果我們自己做一個新的 CQE，我不會只做：



我會設計成這樣：



其中：

$$h_t = \text{Fusion}(h_{\text{text}}, h_{\text{speech}}, h_{\text{interaction}})$$

然後：

$$Q_t = g(h_1, \dots, h_t)$$

$$Q_D = g(h_1, \dots, h_T)$$

這就是 **Hierarchical Multimodal Conversation Quality Estimation** 。

10. 我特別建議把它變成 Multi-task Learning

不要只訓練：

$$Loss_{\text{overall}}$$

而是：

$$L = \lambda_1 L_{\text{turn}} + \lambda_2 L_{\text{dialogue}} + \lambda_3 L_{\text{coherence}} + \lambda_4 L_{\text{engagement}} + \lambda_5 L_{\text{satisfaction}}$$

模型最後可以輸出：

```
{  
  "overall": 4.1,  
  "coherence": 4.6,  
  "relevance": 4.3,  
  "engagement": 3.5,  
  "naturalness": 3.9,  
  "efficiency": 4.2,  
  "user_satisfaction": 4.0  
}
```

這會比：

```
{"quality": 4.1}
```

更具有研究價值，也更容易解釋模型錯在哪裡。

11. Dataset 現在其實已經可以開始做

一個很好的起點是 DSTC10 Automatic Dialogue Evaluation repository，因為它已經整理多個 benchmark，包括：

Dataset	Level	Dimensions
PersonaChat-USR	Turn	6
TopicalChat-USR	Turn	6
FED-Turn	Turn	9

Dataset	Level	Dimensions
FED-Conversation	Dialogue	11
DailyDialog	Turn	multiple
EmpatheticDialogues	Turn	quality
ConvAI2	Turn	quality

而且官方整理頁面提供各 dataset 的 instance 數量和 annotation granularity，非常適合建立 baseline benchmark。

來源：https://github.com/e0397123/dstc10_metric_track

中文則可以加入 **CMT-Eval**。它有 596 段對話、4,431 turns，而且特別針對 realistic multi-turn challenges、speech acts、personas 做細粒度評估。

來源：<https://aclanthology.org/2025.findings-emnlp.992/>

12. 2026 值得特別注意：Audio Conversation Benchmark

今年已經明顯看到 research 從：

text dialogue

走向：

spoken multi-turn conversation

例如 Interspeech 2026 的 **MSU-Bench** 已開始系統性評估 multi-speaker conversational audio understanding，涵蓋 speaker、interaction 與 paralinguistic information。資料與 benchmark 也已公開。

來源：<https://github.com/ASLP-lab/MSU-Bench>

ACL 2026 的一些 benchmark 甚至開始直接把 **interruptions**、**pauses**、**background interference**、**long-context dialogue quality** 加入 spoken dialogue evaluation。

來源：<https://huggingface.co/datasets/Jeff0918/MTR-DuplexBench/blob/main/README.md>

這對 CQE 非常重要，因為 research frontier 正從：

TextQuality

變成：

ConversationalBehaviorQuality

13. 我認為目前真正的 Research Gap

目前大多數方法仍存在一個斷層。

Text/NLP 社群主要做：

$$Context + Response \rightarrow Quality$$

Speech 社群比較常做：

$$Audio \rightarrow Emotion/Engagement$$

但真正的 conversation quality 應該是：

$$ConversationQuality = SemanticQuality + InteractionQuality + AcousticQuality + UserState$$

而且：

$$Q_t \neq Q_{t-1}$$

Conversation quality 本質上是隨時間演化的 **latent state**。

這一點其實讓它很像 speech scoring，但多了一個 temporal interaction structure。

14. 我建議我們接下來正式研究這個題目

我會把研究主題暫時命名成：

Multimodal Turn-level and Dialogue-level Conversation Quality Estimation using Speech, Linguistic and Interaction Dynamics

中文可以稱：

融合語音、語意與互動動態之多模態對話品質估計

初步可以有四個 Research Questions：

1. **RQ1**：Text-only LLM embedding 是否足以預測 Conversation Quality？
2. **RQ2**：加入 prosody / acoustic embedding 能改善多少？
3. **RQ3**：Turn-taking、pause、overlap、latency 是否提供獨立於 text 的 quality information？
4. **RQ4**：Turn-level CQ trajectory 是否能比單純 whole-dialogue embedding 更準確預測整體 satisfaction？

我尤其看好 **RQ3 + RQ4**。因為這兩個方向不只是「換一個更大的 LLM」，而是在重新建模 conversation quality 的本質。

下一階段我建議直接進入真正的研究流程：我可以接著替你整理一份 **2015–2026 Conversation Quality Estimation literature map**，把論文分成 **User Satisfaction**、**Dialogue Evaluation**、**Speech/Prosody**、**Turn-taking**、**LLM-as-a-Judge**、**Multimodal** 六條線，並進一步找出 20–30 篇最重要論文、dataset、GitHub/PDF、模型架構與可以投稿 ACL / EMNLP / Interspeech / ICASSP 的 research gap。

Turn 2 — User

若把研究範圍縮小到 RAG 回覆品質的評估呢？

Assistant (進度更新)

可以，而且把範圍縮到 **RAG 回覆品質評估** 之後，題目會更聚焦，也更容易做成可重現的 benchmark。核心可以從「整段對話品質」改成：**檢索是否正確、答案是否忠實於證據、答案是否真的解決問題，以及如何把這些因素合成一個可靠的品質分數。**

Assistant

可以，而且我反而認為把題目縮到「**RAG 回覆品質估計 (RAG Response Quality Estimation)**」，會比泛化的 Conversation Quality Estimation 更容易形成明確的研究問題、資料標註規範與 benchmark。

關鍵是再做一次切割：**我們不是要評估整個 RAG pipeline，而是評估「在給定 Query 與 Retrieved Context 的條件下，這個 Answer 到底有多好」。**

1. 先把研究問題定義清楚

典型 RAG 是：

$$q \rightarrow \text{Retriever} \rightarrow C \rightarrow \text{LLM} \rightarrow A$$

其中：

$$C = \{c_1, c_2, \dots, c_k\}$$

如果做完整 RAG evaluation，會同時研究：

$$\text{Retriever Quality} + \text{Generation Quality}$$

但如果我們現在專注在 **Response Quality**，我會把問題定義成：

$$Q = f(q, C, A)$$

其中：

- q : User Query
- C : Retrieved Context
- A : RAG Response
- Q : Response Quality

這個 framing 很重要。

因為 Retrieved Context 在我們的研究中不是主要被評估的 target，而是 **evidence**。

換句話說，我們問的是：

「已知 RAG 找到了這些資料，LLM 所產生的回答是否是一個高品質回答？」

2. RAG Response Quality 不是單一分數

目前最成熟的 RAG evaluation 工作基本上都支持 multi-dimensional evaluation。RAGAS 把 retrieval/context、faithfulness 和 answer quality 分開；ARES 則明確以 context relevance、answer faithfulness、answer relevance 來評估 RAG。

來源：<https://aclanthology.org/2024.eacl-demo.16/>

如果聚焦「Response」，我建議至少定義以下六個 dimension：

Dimension	核心問題
Faithfulness	Answer 的敘述是否有 retrieved context 支持？
Correctness	Answer 是否真的正確？
Completeness	Context 中與問題相關的重要資訊是否都有回答？
Relevance	Answer 是否真正回答 user query？
Hallucination	是否包含 context 無法支持甚至衝突的資訊？
Conciseness / Irrelevance	是否加入大量無關、冗餘資訊？

2025 ACL 的 RAGEval 也特別提出 **Completeness、Hallucination、Irrelevance** 三項 response-level 指標，說明現在研究已經逐漸從「correct / incorrect」轉向更細粒度的回答品質。

來源：<https://aclanthology.org/2025.acl-long.418/>

所以比較好的形式不是：

$$Quality=0.82$$

而是：

$$Q(A)=\left[F,C,R,H,I\right]$$

例如：

Faithfulness : 0.93
Correctness : 0.88
Completeness : 0.71
Relevance : 0.95
Hallucination: 0.08

最後才可以選擇是否產生：

$$Q_{overall}$$

3. 我認為最值得研究的是 Claim-level Evaluation

這可能會是整個題目的核心。

傳統方法很容易直接：

Question
Context

Answer
↓
LLM Judge
↓
4 / 5

問題是這個 4 分到底是什麼意思？

假設回答：

台積電成立於 1987 年，總部位於新竹，目前是全球最大的半導體公司，而且由張忠謀擔任董事長。

這裡其實包含多個 claims：

$$A = \{a_1, a_2, a_3, a_4\}$$

應該拆成：

- Claim 1: 台積電成立於 1987
- Claim 2: 總部位於新竹
- Claim 3: 是全球最大的半導體公司
- Claim 4: 張忠謀目前擔任董事長

接下來對每個 claim 尋找 retrieved evidence：

$$a_i \leftrightarrow C$$

然後分類：

$$\text{Support}(a_i, C) \in \{\text{Supported}, \text{Contradicted}, \text{Insufficient}\}$$

這就把模糊的：

「這個回答好不好？」

轉成：

「這個回答裡面的每個 factual claim，有多少是真的被 evidence 支持？」

RAGTruth 就採取非常細的 hallucination annotation，包含接近 18,000 個自然生成的 RAG responses，並有人工作到 response 與 word-level 的 hallucination annotation。

來源：<https://aclanthology.org/2024.acl-long.585/>


這是一個很重要的研究方向。

4. 我會把模型設計成這樣

我們可以建立一個：

Evidence-aware RAG Response Quality Estimator

User Query
|



我認為這個 architecture 比直接用 GPT-5 / Claude：

Please rate this answer from 1-5.

有研究價值得多。

5. 為什麼「LLM-as-a-Judge」本身就有研究空間

這是目前非常重要的問題。

現在 RAG evaluation 很多方法其實高度依賴：

LLM as Judge

但 2025 ACL 的 **ConsJudge** 發現，RAG evaluation 的 LLM judges 對 evaluation prompt 相當敏感，同一答案在不同 judging configuration 下可能產生不一致判斷，因此專門提出 judge-consistency training。

來源：<https://aclanthology.org/2025.findings-acl.301/>

更廣泛的 2025 EMNLP meta-evaluation 研究還發現：當兩個待比較系統能力非常接近時，LLM evaluator 與 human judgement 的 correlation 會明顯下降。也就是說，一個 judge 很會區別「很差 vs 很好」，不代表它很會區別：

$$RAG_A=0.83$$

和：

$$RAG_B=0.85$$

這對實際 RAG development 非常重要。

來源：<https://aclanthology.org/2025.findings-emnlp.1036/>

因此我們可以把研究目標進一步變成：

$$ReliableRAGResponseQualityEstimation$$

而不只是：

$$RAGEvaluation$$

6. 這裡開始出現一個很漂亮的研究問題

我認為可以研究：

Can fine-grained claim-level evidence verification provide a more reliable estimate of RAG response quality than direct LLM-as-a-Judge scoring?

中文：

基於 Claim-level Evidence Verification 的 RAG 回覆品質估計，是否能比直接 LLM-as-a-Judge 評分更接近人類判斷？

這個問題非常乾淨。

7. Baseline 已經很清楚

可以直接比較：

Method	方法
RAGAS	reference-free metric suite
ARES	trained lightweight LM judges
RAGChecker	fine-grained RAG diagnostics
GPT/Claude Judge	direct LLM-as-a-Judge
ConsJudge	consistency-oriented judge
RAG-Zeval	reasoning + RL evaluator
Ours	claim-level evidence-aware quality estimator

RAGChecker 特別值得作 baseline，因為它已經在做 retrieval / generation 細粒度 diagnosis，而且其 meta-evaluation 報告比若干既有 RAG metrics 與 human judgments 有更好的相關性。

來源：<https://arxiv.org/abs/2408.08067>

2025 EMNLP 的 RAG-Zeval 則代表另一條最新路線：把 faithfulness / correctness evaluation 視為 reasoning task，利用 RL 訓練較小 evaluator，而且論文報告其 evaluator 能以遠小於大型 judge 的參數量取得很強的人類判斷相關性。

來源：<https://aclanthology.org/2025.emnlp-main.1267/>

8. 我會把研究再收斂成三層

這樣論文會很好寫：

Layer 1 — Claim Quality

對 Answer A 做：

$$A \rightarrow \{c_1, c_2, \dots, c_n\}$$

每個 claim：

$$s_i = \text{Support}(c_i, C)$$

得到：

$$\text{Faithfulness} = \frac{\text{Supported Claims}}{\text{Claims}}$$

可以進一步加入 claim importance：

$$\text{Faithfulness} = \frac{\sum_i w_i s_i}{\sum_i w_i}$$

這個 w_i 很值得研究。

因為：

「產品價格是 100 元」

錯誤，和

「成立於 1998 年」

錯誤，在某些 query 中重要程度可能完全不同。

Layer 2 — Answer Coverage

另一個問題完全相反。

不是：

Answer 說的是不是真的？

而是：

應該回答的東西有沒有回答？

定義：

$$InformationNeed(q, C) = \{r_1, r_2, \dots, r_m\}$$

然後：

$$Completeness = \frac{AnsweredRequiredClaims}{RequiredClaims}$$

這可以解決一個 RAG evaluation 常見問題：

答案完全沒有 hallucination，

但它只回答了問題的一半。

例如：

比較 A 與 B 的價格、效能與耗電。

RAG 回答：

A 的效能比 B 高 20%。

全部 factual。

可是：

$$Completeness \ll 1$$

Layer 3 — User-query Alignment

最後才是：

$$Relevance(A, q)$$

也就是：

有沒有真正解決 User Information Need？

因此我們最後可以建立：

$$RAGQE = f(Faithfulness, Completeness, Relevance, Correctness)$$

我暫時會把這個模型叫：

RAGQE — Retrieval-Augmented Generation Quality Estimator

9. 最有意思的地方其實是「不要只輸出分數」

我會讓模型輸出：

```
{
  "overall_quality": 0.81,

  "faithfulness": 0.91,
  "completeness": 0.72,
  "relevance": 0.93,

  "claims": [
    {
      "claim": "...",
      "evidence": "document_2 chunk_5",
      "status": "supported",
      "confidence": 0.96
    },
    {
      "claim": "...",
      "evidence": null,
      "status": "unsupported",
      "confidence": 0.88
    }
  ],

  "missing_information": [
    "..."
  ]
}
```

這樣它不再只是 evaluator。

而是：

Score+Diagnosis+Explanation

這對實務 RAG system 特別有價值。

因為 evaluator 可以直接告訴 developer：

Retriever 問題？

↓

Context 不完整？

Generator 問題？

↓

有 context 卻沒有使用？

Hallucination？

↓

生成 context 外資訊？

Coverage 問題？

↓
漏掉重要資訊？

10. 我認為研究亮點可以放在「Reliability」

如果只是再做一個：

GPT 幫 RAG 打分工具

現在已經不太新。

但如果研究題目變成：

Fine-grained, Evidence-aware and Calibrated RAG Response Quality Estimation

就明顯不同。

尤其可以研究：

Quality+Confidence

例如：

Quality = 0.87

Confidence = 0.95

或者：

Quality = 0.72

Confidence = 0.41

第二個案例代表 evaluator 自己也不確定。

這在 production 特別重要。

11. 實驗怎麼做也很清楚

我會採用下面這個實驗矩陣：

Experiment	問題
E1	direct LLM judge vs claim-level judge
E2	有/無 evidence alignment
E3	binary checklist vs 1–5 Likert
E4	whole-response vs claim-level
E5	general-domain vs domain-specific
E6	English vs Chinese
E7	large judge vs small trained evaluator
E8	response score vs human score

其中 **E3 很值得做**。

2025 EMNLP 的 CheckEval 發現，把模糊的 Likert 評分拆成可驗證的 binary checklist，能明顯提升不同 evaluator models 之間的一致性，並降低 score variance。

來源：<https://aclanthology.org/2025.emnlp-main.796/>

例如不要問：

Faithfulness 1-5 分？

而問：

Claim 1 有 evidence support？ Yes / No

Claim 2 有 evidence support？ Yes / No

Claim 3 與 evidence contradiction？ Yes / No

Question 的必要資訊 A 有回答？ Yes / No

Question 的必要資訊 B 有回答？ Yes / No

最後：

$$Score = Aggregation(binary\ decisions)$$

這會非常適合 RAG。

12. 我會建議你把論文題目定成這個方向

暫定英文題目

Fine-grained Evidence-Aware Quality Estimation for Retrieval-Augmented Generation Responses

或者更強調可靠性：

Reliable RAG Response Quality Estimation through Claim-Level Evidence Verification

中文：

基於細粒度 Claim-Level 證據驗證之 RAG 回覆品質估計

研究模型可以濃縮成：

Query + Retrieved Evidence + Response → Claim Decomposition → Evidence Verification → C

這比我們前面討論的泛化 Conversation Quality **更適合先做成一篇研究**：target 明確、baseline 成熟、公開資料可用，而且 2024-2026 的研究也清楚顯示 **LLM judge reliability**、**fine-grained diagnosis**、**faithfulness** 與 **completeness** 還有很大的研究空間。

來源：<https://aclanthology.org/2024.eacl-demo.16/>

如果繼續往下做，我下一步會直接把它發展成一份 **Research Proposal v0.1**：包括 **Problem Definition → Literature Gap → RQ1-RQ4 → 模型 architecture → Dataset → Baselines → Evaluation Metrics → Ablation Study**，並且我會特別把「**如何超越 RAGAS / RAGChecker，而不是重新做一次它們**」定義清楚。

Turn 3 — User

針對「Fine-grained Evidence-Aware Quality Estimation for Retrieval-Augmented Generation Responses」幫我
把研究的動機(也就是要解進的問題)、步驟、架構、可能需要閱讀的相關論文，進行收集跟整理。

Assistant (進度更新)

我會把它整理成一份接近「研究計畫書前半部」的形式：先界定**現有 RAG evaluation 哪裡不夠**，再整理成可驗證的
research questions，接著給出一個可實作的 fine-grained evidence-aware 架構與實驗步驟，最後附上分層的必讀
論文清單。重點會放在「**如何超越直接 LLM-as-a-Judge 與現有 RAG metrics**」，而不是再做一套相似的評分器。

Assistant (研究整理)

目前文獻掃描後，我認為題目可以再精準一點：真正有機會形成 contribution 的不是單純「claim-level
faithfulness」，因為 **FActScore**、**RefChecker**、**RAGChecker**、**RAGTruth** 已經涵蓋不少；比較有空間的是把
「**使用者問題需要哪些資訊**」與「**回答中的每個 claim 被哪些 evidence 支持**」同時建模，再處理 evaluator 的不確
定性。2025 年的工作也指出 claim decomposition 本身會影響 verification 結果，所以「先拆 claim 再判斷」不能
被當成可靠的固定前處理。

Assistant

可以。我把這個題目重新整理成一個可以真正開始做的 research proposal。先給結論：

**「Fine-grained Evidence-Aware Quality Estimation for RAG Responses」最值得研究的核心，不
應只是再做一個 Faithfulness metric，而應該同時回答兩件事：**

\\(1\\) Answer 中 每 一 個 claim，有 沒 有 被

\\(2\\) Query 正 要 求 的 重 要 資 訊，Answer 有 ；

再加上第三個目前愈來愈重要的問題：

\\(3\\) Evaluator 自 己 對 這 個 判 斷

這三者合起來，我認為會比單純 RAGAS / LLM-as-a-Judge 更有研究價值。

一、研究題目先重新精確定義

我建議正式題目暫定為：

**Fine-grained Evidence-Aware Quality Estimation for Retrieval-Augmented Generation
Responses**

也可以進一步寫成：

**Reliable Fine-grained RAG Response Quality Estimation through Query-aware Claim
Decomposition and Evidence Verification**

中文：

這個版本把真正可能的 contribution 說得更清楚。

二、研究動機：到底想解決什麼問題？

2026 最新的 RAG evaluation review 仍指出，目前 RAG evaluation 缺乏一致的多維度標準，而且 fine-grained、diagnostic evaluation 仍然是重要缺口；尤其只有一個 aggregate score 時，很難知道錯誤究竟來自 retrieval、grounding、reasoning 還是 generation。

來源：<https://link.springer.com/article/10.1007/s42979-026-05134-x>

我認為可以把問題整理成 **五個核心缺陷**。

Problem 1：整體分數無法告訴我們「哪裡錯」

最簡單的 evaluator 是：

Query
Context
Answer
↓
LLM Judge
↓
Quality = 3.8 / 5

這個分數幾乎沒有 debugging value。

例如 Answer 有四個 claims：

Claim A → correct
Claim B → correct
Claim C → unsupported
Claim D → contradicted

最後得到：

3.5 / 5

我們不知道：

- 哪個 claim 有問題
- 哪份 document 支持哪個 claim
- 是否漏掉重要資訊
- 問題來自 retriever 還是 generator

RAGChecker 就是針對這個問題提出 fine-grained diagnostic metrics，而且其 meta-evaluation 顯示，細粒度評估和 human judgments 的相關性優於多項既有 RAG metrics。

來源：https://proceedings.neurips.cc/paper_files/paper/2024/hash/27245589131d17368cccdfa990cbf16e-Abstract.html

所以：

三、Problem 2 : Faithfulness $\neq$ Correctness $\neq$ Completeness

這三件事一定要拆開。

假設 Context :

公司規定退貨期限為 30 天。

Answer :

商品可以在 30 天內退貨。

這是：

$$Faithful = True$$

如果公司真正規定也是如此：

$$Correct = True$$

但是假設 Query 是：

特價商品可以退嗎？期限多久？

而 Answer 只有：

可以在 30 天內退貨。

它可能完全沒有 hallucination：

$$Faithfulness = 1$$

但卻沒有回答：

特價商品是否屬例外？

所以：

$$Completeness < 1$$

RAGEval 也因此特別把 **Completeness**、**Hallucination**、**Irrelevance** 分離成不同 evaluation dimensions。

來源：<https://aclanthology.org/2025.acl-long.418/>

2025 NAACL 更直接研究：

Do RAG Systems Cover What Matters?

它把 Query 分解成 sub-questions，並區分 core、background 和 follow-up facets；研究甚至發現，商用 answer engines 對 core sub-questions 都可能漏掉相當大的比例。

來源：<https://aclanthology.org/2025.naacl-long.301/>

這非常重要。

因此：

Faithfulness does not imply completeness

四、Problem 3 : Claim decomposition 本身會犯錯

很多 evaluation framework 現在採用：

Answer $\rightarrow$ *Atomic Claims* $\rightarrow$ *Verification*

這條路線是對的。

FactScore 很早就證明：long-form answer 不能簡單判斷「對 / 錯」，應該拆成 atomic facts，再計算多少 facts 被 evidence 支持。

來源：<https://aclanthology.org/2023.emnlp-main.741/>

RefChecker 更使用 claim-triplets：

$(head, relation, tail)$

來進行 fine-grained hallucination checking，並報告比 response、sentence、sub-sentence level 的方法更好的 hallucination detection。

來源：<https://arxiv.org/abs/2405.14486>

但新的問題出現了：

Claim decomposition 自己也不是可靠的。

例如：

Apple 在 2025 年推出 X，售價 999 美元，而且成為當年最暢銷產品。

可以拆：

C1: Apple 在 2025 年推出 X

C2: X 售價 999 美元

C3: X 是當年最暢銷產品

也可能拆：

C1: Apple 在 2025 年以 999 美元推出 X

C2: X 成為當年最暢銷產品

不同 atomicity 會影響 verifier。

ACL 2025 的 **Optimizing Decomposition for Optimal Claim Verification** 明確發現 decomposition policy 和 downstream verifier 之間可能 misalign；論文透過動態 decomposition 改善 verification accuracy。

來源：<https://aclanthology.org/2025.acl-long.254/>

EMNLP 2025 的 DnDScore 更指出 decomposition 與 decontextualization 之間存在 tension，選擇不同 strategy 會直接改變最後 factuality score。

來源：<https://aclanthology.org/2025.emnlp-main.1205/>

所以：

Claim extraction cannot be treated as a perfect preprocessing step

這就是很好的研究切入口。

五、Problem 4：LLM-as-a-Judge 不夠穩定

現在很多 RAG evaluator 的本質就是：

LLM(prompt, query, context, answer)

然後輸出：

Faithfulness = 4

問題是 evaluator 會受到：

- Prompt wording
- Scale definition
- Evaluator model
- Criteria order
- Context length
- Reasoning strategy

影響。

ConsJudge 就針對 RAG evaluation 發現 judge 對不同 evaluation prompts 會產生 inconsistent judgments，進而透過 judge consistency 來訓練 evaluator。

來源：<https://aclanthology.org/2025.findings-acl.301/>

CheckEval 則從另一個角度解：

不要問：

Faithfulness 1-5？

而是拆成：

Claim 1 是否有 evidence？Yes / No

Claim 2 是否有 evidence？Yes / No

Claim 3 是否 contradiction？Yes / No

它報告 checklist-based binary decisions 可以提升 evaluator 間的一致性並降低評分 variance。

來源：<https://aclanthology.org/2025.emnlp-main.796/>

這非常適合我們的研究。

六、Problem 5 : Evaluator 不知道自己何時「不知道」

這是我認為可以讓你的研究比既有 framework 再進一步的一點。

假設：

Query

↓

Retrieved Context

本身只有部分資訊。

Evaluator 卻強迫回答：

Supported / Unsupported

其實合理答案可能是：

Insufficient Evidence

因此 claim verification 應該至少是：

$$V(c_i, E) \in \{Supported, Contradicted, Insufficient\}$$

而不是：

$$\{True, False\}$$

2025 ACL 也特別提出 UAEval4RAG，研究 RAG 在 knowledge base 無法回答問題時是否能正確 abstain，而不是硬生成答案。

來源：<https://aclanthology.org/2025.acl-long.415/>

2026 也已開始出現專門研究 evidence sufficiency 和 answer-abstention calibration 的 benchmark。

來源：<https://www.sciencedirect.com/org/science/article/pii/S1546221826007526>

所以：

$$Evaluatoruncertainty$$

本身應該成為研究的一部分。

七、因此真正的 Research Gap

綜合目前文獻，我認為可以把 gap 寫成：

現有 RAG evaluation 多半分別研究 faithfulness、answer relevance、retrieval relevance 或 hallucination；雖然近期方法開始採用 fine-grained claim verification，但仍缺乏一個同時從 **Query information needs** 與 **Answer claims** 兩端建立顯式對齊，並考慮 claim decomposition reliability、evidence sufficiency 與 evaluator confidence 的品質估計框架。

用數學來講就是：

現有方法多半：

$$A \rightarrow Claims \rightarrow Evidence$$

我們要做：

$$Query \rightarrow InformationRequirements$$

以及：

$$Answer \rightarrow Claims \rightarrow Evidence$$

最後兩條路徑相遇。

這是整個研究最重要的概念。

八、我建議的核心架構

我暫時命名：

EviRAG-QE

Evidence-aware RAG Quality Estimator

整體架構：





九、Stage 1 : Query Requirement Decomposition

Query :

比較 MacBook Air M4 和 MacBook Pro M4 的價格、重量與續航，並告訴我哪一款比較適合經常出差。

不要直接拿 Query embedding 評 Answer。

先拆：

$$R = \{r_1, r_2, \dots, r_m\}$$

例如：

- R1: MacBook Air M4 價格
- R2: MacBook Pro M4 價格
- R3: Air 重量
- R4: Pro 重量
- R5: Air 續航
- R6: Pro 續航
- R7: 根據上述資訊比較出差適用性

然後賦予 importance：

$$w_j$$

例如：

price 0.15
weight 0.25
battery 0.25
travel fit 0.35

這讓我們可以計算：

$$WeightedCoverage = \frac{\sum_j w_j I(r_j covered)}{\sum_j w_j}$$

這比普通 answer relevance 更有解釋性。

十、Stage 2 : Answer Claim Decomposition

把：

A

轉成：

$$C = \{c_1, c_2, \dots, c_n\}$$

但這裡不要只要求 atomic。

每個 claim 還可以有：

```
{  
  "claim": "...",  
  "type": "factual",  
  "importance": 0.83,  
  "query_facet": "battery_life",  
  "verifiability": 0.97  
}
```

我會區分至少：

Factual claim
Inferential claim
Recommendation
Opinion / style

這很重要。

因為：

「MacBook Air 比較適合出差」

不能單純用 NLI 去問：

Context 是否 entail ?

它其實是：

Inference

需要從：

weight + battery + price

推論。

十一、Stage 3 : Claim ↔ Evidence Alignment

我們建立：

$$M_{ij} = \text{Similarity}(c_i, e_j)$$

首先找到 candidate evidence：

$$\text{TopK}(c_i, E)$$

然後 verifier 判斷：

$$V(c_i, e_j)$$

三類：

SUPPORTED
CONTRADICTED
INSUFFICIENT

例如：

```
{  
  "claim": "Air weighs 1.24kg",  
  "evidence": "doc3_chunk7",  
  "relation": "SUPPORTED",  
  "confidence": 0.97  
}
```

這裡可以用：

- NLI model
- LLM verifier
- Cross-encoder
- small fine-tuned LLM

做比較。

十二、Stage 4 : 建立 Evidence Graph

我甚至建議不要只是 table。

建立：

$$G = (R, C, E)$$


三種 nodes：

Requirement nodes
Claim nodes
Evidence nodes

Edges :

Requirement → Claim
Claim → Evidence

例如 :



如此一來 :

Faithfulness

看 :

$$Claim \rightarrow Evidence$$

Completeness

看 :

$$Requirement \rightarrow Claim$$

Evidence Coverage

看 :

$$Evidence \rightarrow Claim$$

這是一個很漂亮的統一 representation 。

十三、我們的主要 Metrics

1. Claim Faithfulness

$$F = \frac{\sum_i w_i I(c_i = Supported)}{\sum_i w_i}$$

2. Contradiction Rate

$$CR = \frac{\text{Contradicted}}{\text{Claims}}$$

3. Query Coverage

$$QC = \frac{\sum_j w_j I(r_j \text{ covered})}{\sum_j w_j}$$

4. Unsupported Claim Rate

$$UCR = \frac{\text{Insufficient}}{\text{Claims}}$$

5. Irrelevance

Answer 裡存在：

Claim

卻：

Claim $\rightarrow$ / *Query Requirement*

就可以被視為 potential irrelevant information。

十四、Overall Quality 不要手工平均

不要簡單：

$$Q = 0.25 F + 0.25 C + 0.25 R + 0.25 \dots$$

這很難 justify。

比較好的方式：

$$Q = g_{\theta}(\text{Faithfulness}, \text{Coverage}, \text{Contradiction}, \text{Relevance}, \text{Confidence}, \dots)$$

其中：

g_{θ}

可以是很小的：

- Logistic / ordinal regression
- Gradient boosting
- Small MLP
- Pairwise ranking head

用 human quality judgments 學。

如此得到：

$$Q_{overall}$$

但底下 metrics 仍然保持 interpretable。

十五、Confidence 是這篇研究可能很重要的特色

Verifier 不只輸出：

SUPPORTED

而是：

SUPPORTED 0.94

或者：

SUPPORTED 0.38
CONTRADICTED 0.19
INSUFFICIENT 0.43

後者其實應該標：

UNCERTAIN

最後：

$$\begin{aligned}Quality &= 0.82 \\Confidence &= 0.91\end{aligned}$$

與：

$$\begin{aligned}Quality &= 0.82 \\Confidence &= 0.43\end{aligned}$$

意義完全不同。

十六、Research Questions 可以定成四個

我認為這四個很漂亮：

RQ1

Does query-aware claim evaluation correlate better with human judgments than direct response-level RAG evaluation?

比較：

$$DirectJudge$$

VS

Query Requirements+Claims+Evidence

RQ2

Does fine-grained claim-evidence alignment improve faithfulness and hallucination detection?

比較：

whole answer

sentence

atomic claim

claim triplet

adaptive claim

RQ3

Does importance-weighted query coverage provide a better estimate of answer completeness than conventional answer relevance metrics?

這就是我們和很多 RAG evaluation 方法最明顯的差異。

RQ4

Can confidence calibration identify unreliable evaluator decisions under incomplete, noisy, or conflicting retrieval contexts?

這則處理 evaluator reliability。

十七、可以進一步寫成四個 Hypotheses

$$H_1: \text{Corr}(Q_{ours}, \text{Human}) > \text{Corr}(Q_{baseline}, \text{Human})$$

$$H_2: \text{ClaimLevelVerification} > \text{ResponseLevelVerification}$$

$$H_3: \text{WeightedQueryCoverage} > \text{AnswerRelevance}$$

對於 completeness prediction。

以及：

$$H_4: \text{CalibratedEvaluator}$$

在 noisy / insufficient contexts 上具有較好的：

$$ECE, \text{BrierScore}$$

十八、完整研究步驟

我會按照下面順序做，而不是一開始就 train model。

Phase	工作	Output
1	文獻 taxonomy	metric / dataset / problem map
2	Formal problem definition	Q, C, A, E, R 定義
3	Human annotation protocol	gold labels
4	Baseline reproduction	RAGAS / ARES / RAGChecker
5	Claim decomposition	atomic claims
6	Query decomposition	information requirements
7	Evidence alignment	claim $\leftrightarrow$ evidence
8	Verification	support / contradict / insufficient
9	Quality aggregation	multidimensional scores
10	Calibration	confidence
11	Meta-evaluation	human correlation
12	Ablation	contribution analysis

十九、Dataset 怎麼選

我建議不要一開始自己建立全部資料。

先用公開資料。

RAGTruth

接近 **18,000 RAG responses**，含人工 hallucination annotation，非常適合：

ClaimVerification

與：

HallucinationDetection

實驗。

來源：<https://aclanthology.org/2024.acl-long.585/>

RAGBench

約 **100k examples**、五個 industry-oriented domains，並提出 TRACe：

utilization / relevance / adherence / completeness

對實務型 RAG quality evaluator 特別有價值。

來源：<https://arxiv.org/abs/2407.11005>

RAGEval

適合：

Completeness
Hallucination
Irrelevance

而且特別考慮 scenario-specific RAG。

來源：<https://aclanthology.org/2025.acl-long.418/>

ALCE

如果要研究：

$$Claim \leftrightarrow Citation$$

一定值得用。

它包含：

- ASQA
- QAMPARI
- ELI5

並評估 fluency、correctness 和 citation quality。

來源：<https://aclanthology.org/2023.emnlp-main.398/>

RGB

很適合 robustness：

Noise robustness
Negative rejection
Information integration
Counterfactual robustness

而且有英文與中文資料。

來源：<https://mlanthology.org/aaai/2024/chen2024aaai-benchmarking/>

FRAMES

如果未來要進到 multi-hop：

$$Evidence_1 + Evidence_2 + \dots \rightarrow Answer$$

FRAMES 專門測 factuality、retrieval 與 reasoning，問題本身就需要 multi-source information integration。

來源：<https://aclanthology.org/2025.naacl-long.243/>

二十、Baselines 一定要有

至少比較：

Baseline	用途
RAGAS	standard reference-free RAG evaluation
ARES	trained lightweight evaluator
RAGChecker	fine-grained RAG diagnostics
RAGBench / TRACe	explainable industrial metrics
RAGEval	completeness / hallucination / irrelevance
GPT-class direct judge	LLM-as-a-Judge
RefChecker	claim-level hallucination
Ours	query-aware claim-evidence quality

RAGAS 是最基本 baseline，強調不依賴 ground-truth reference 進行多維 RAG evaluation。

來源：<https://aclanthology.org/2024.eacl-demo.16/>

ARES 則透過 synthetic training data 訓練 lightweight LM judges，並使用少量 human annotations 做 prediction-powered inference。

來源：<https://aclanthology.org/2024.naacl-long.20/>

二十一、Meta-evaluation 才是整篇論文最重要的實驗

不是問：

我們的 quality score 是多少？

而是問：

我們的 evaluator 到底是不是一個好的 evaluator？

Gold standard：

HumanJudgement

然後比較：

EvaluatorScore ↔ HumanScore

可以用：

Pearson r
Spearman ρ
Kendall τ

如果是：

SUPPORTED / CONTRADICTED / INSUFFICIENT

使用：

Accuracy
Macro-F1
Cohen κ

若做人類多人標註：

Krippendorff α

Confidence calibration：

ECE
Brier Score
NLL

二十二、Ablation Study

這一塊幾乎已經可以直接規劃。

- Full model
↓
- Query decomposition
- Claim decomposition
- Claim importance
- Evidence alignment
- Decontextualization
- Confidence calibration

然後觀察：

$$\Delta HumanCorrelation$$

我特別期待：

- Query decomposition

對：

$$Completeness$$

造成很明顯的下降。

二十三、最值得優先閱讀的論文

我會按照這個順序讀，而不是 chronological reading：

Priority	Paper	為什麼讀
★★★★★	RAGAS — Es et al., 2024	RAG evaluation 基礎 taxonomy。 https://aclanthology.org/2024.eacl-demo.16/
★★★★★	ARES — Saad-Falcon et al., 2024	學習型 evaluator + human calibration。 https://aclanthology.org/2024.naacl-long.20/
★★★★★	RAGChecker — Ru et al., 2024	最接近我們 fine-grained diagnostic 的 baseline。 https://proceedings.neurips .

Priority	Paper	為什麼讀
		cc/paper_files/paper/2024/hash/27245589131d17368cccdfa990cbf16e-Abstract.html
★★★★★	RefChecker — Hu et al., 2024	claim-triplet verification，直接影響我們 claim representation。https://arxiv.org/abs/2405.14486
★★★★★	RAGTruth — Niu et al., ACL 2024	hallucination dataset 與標註方式。https://aclanthology.org/2024.acl-long.585/
★★★★★	Do RAG Systems Cover What Matters? — NAACL 2025	Query decomposition / sub-question coverage，是我們 completeness 設計的關鍵。https://aclanthology.org/2025.naacl-long.301/
★★★★★	Optimizing Decomposition for Optimal Claim Verification — ACL 2025	告訴你 claim decomposition 不能視為 fixed preprocessing。https://aclanthology.org/2025.acl-long.254/
★★★★★	CheckEval — EMNLP 2025	binary checklist 比 Likert evaluator 更穩定。https://aclanthology.org/2025.emnlp-main.796/
★★★★☆	FactScore — EMNLP 2023	atomic factuality 的經典起點。https://aclanthology.org/2023.emnlp-main.741/
★★★★☆	VeriScore — EMNLP 2024	claim extraction → retrieval → verification 的完整 pipeline。https://aclanthology.org/2024.findings-emnlp.552/
★★★★☆	ALCE — EMNLP 2023	citation correctness / completeness。https://aclanthology.org/2023.emnlp-main.398/
★★★★☆	ConsJudge — ACL 2025	RAG judge consistency 問題。https://aclanthology.org/2025.findings-acl.301/
★★★★☆	RAGEval — ACL 2025	Completeness、Hallucination、Irrelevance。https://aclanthology.org/2025.acl-long.418/
★★★★☆	DnDScore — EMNLP 2025	decomposition × decontextualization 問題。https://aclanthology.org/2025.emnlp-main.1205/
★★★☆☆	ContextCite — NeurIPS 2024	找出 generation 真正依賴 context 哪些部分。https://aclanthology.org/neurips/2024/cohenwang2024neurips-contextcite/
★★★☆☆	MIRAGE — EMNLP 2024	從 model internals 做 answer attribution。https://aclanthology.org/2024.emnlp-main.347/
★★★☆☆	FRAMES — NAACL 2025	multi-hop RAG factuality/reasoning benchmark。https://aclanthology.org/2

Priority	Paper	為什麼讀
★★★★☆	UAEval4RAG — ACL 2025	025.naacl-long.243/ unanswerable / abstention。https://aclanthology.org/2025.acl-long.415/
★★★★☆	FaStFact — EMNLP 2025	claim verification pipeline 的效率問題。 https://aclanthology.org/2025.findings-emnlp.1295/

此外，2026 的 comprehensive review 很適合第一篇先讀，用來建立完整 landscape；它整理了 context relevance、faithfulness、answer relevance、correctness、citation quality 等 dimension。

來源：<https://link.springer.com/article/10.1007/s42979-026-05134-x>

二十四、有一個 2026 新問題值得留意

今年甚至已經出現更細的 failure：

claim 的確有真實 citation，而且 evidence 本身是真的，但是 **evidence 是在描述錯的 entity**。

例如：

Question: Drug A 有效嗎？

Retrieved Evidence:
Drug B showed 80% response rate.

Answer:
Drug A showed 80% response rate.

從粗略 lexical / citation evaluation：

citation exists ✓
number exists ✓
evidence exists ✓

可是 entity attribution：

Drug B → Drug A

錯了。

2026 一篇 clinical RAG 預印本把這類問題稱為 **deceptive grounding / entity attribution failure**；由於這仍是較新的研究，我會把它當成「第二階段值得加入的 robustness test」，而不是目前主論文的中心。

來源：<https://arxiv.org/abs/2607.09349>

二十五、最後把整篇論文濃縮成一句話

傳統方式：

$$Query + Context + Answer \rightarrow LLM \rightarrow Score$$

我們要研究的是：

$$Query \rightarrow Required Information$$

$$Answer \rightarrow Atomic Claims$$

$$Claims \leftrightarrow Evidence$$

再建立：

$$Requirement \leftrightarrow Claim \leftrightarrow Evidence$$

最後估計：

$$Q = [Faithfulness, Completeness, Relevance, Contradiction, Irrelevance, Confidence]$$

這就是我認為目前最值得做的 **Fine-grained Evidence-Aware RAG Quality Estimation**。

其中真正可能成為論文 contribution 的，不是「又做了一個 RAG evaluator」，而是：

$$Query Information Need + Claim Evidence Grounding + Evaluator Reliability$$

三者放進同一個 unified framework。這個方向與 2023–2026 文獻演進是吻合的，但又沒有簡單重做 RAGAS、RAGChecker 或 RefChecker。

來源：<https://link.springer.com/article/10.1007/s42979-026-05134-x>

如果按照研究執行順序，我建議**下一步先做 Literature Review Matrix**：我可以把上面約 20 篇論文逐篇整理成 **Problem / Method / Dataset / Metrics / Limitation / 與我們研究的關係 / PDF • GitHub 連結**，這份表之後幾乎可以直接轉成論文的 Related Work 與 Proposal 文獻回顧。

Turn 4 — User

我提一下我的觀察，用於衡量 sentence similarity 的方法，進行修改，是否能應用到 RAG answer quality diagnosis

Assistant (進度更新)

這個觀察是成立的，而且我認為很有研究價值：**sentence similarity 不一定只能拿來做「兩句話像不像」**，它可以**被改造成 RAG quality diagnosis 的一個結構化核心**。關鍵在於不能只用單一 cosine similarity，而要把它改成「有方向、有角色、有 coverage、有 contradiction 判斷」的診斷矩陣。

Assistant

可以，而且你的這個觀察其實可以把前面「Fine-grained Evidence-Aware Quality Estimation」再往前推一步。

我會把研究核心從：

$$LLM Judge(Query, Context, Answer) \rightarrow Score$$

改成：

也就是：把 **Sentence Similarity** 從「相似度量測工具」改造成「語意單元之間的 **alignment / diagnosis 工具**」。

這條路值得深入。

1. Sentence Similarity 為什麼很適合 RAG Diagnosis ?

傳統 sentence similarity 是：

$$\text{sim}(s_1, s_2)$$

例如：

S1: MacBook Air M4 weighs 1.24 kg.

S2: The M4 MacBook Air has a weight of 1.24 kg.

SBERT：

$$\cos(e_1, e_2) = 0.94$$

它原本回答的是：

兩個句子的語意有多接近？

但 RAG evaluation 真正需要問的幾個問題，其實都可以轉成 semantic alignment。

例如：

$$\text{sim}(\text{AnswerClaim}, \text{Evidence})$$

→ 這個 claim 能不能在 Context 裡找到對應證據？

$$\text{sim}(\text{QueryRequirement}, \text{AnswerClaim})$$

→ Query 要求的資訊有沒有被回答？

$$\text{sim}(\text{AnswerClaim}, \text{QueryRequirement})$$

→ Answer 裡這句話和使用者問題到底有沒有關係？

所以 sentence similarity 可以從單純：

$$\text{Sentence} \leftrightarrow \text{Sentence}$$

變成：

$$\text{Requirement} \leftrightarrow \text{Claim} \leftrightarrow \text{Evidence}$$

這就非常接近我們前面提出的架構。

2. 但「直接 cosine similarity」一定不夠

這是研究裡最重要的一點。

考慮：

Evidence：MacBook Air M4 weighs **1.24 kg**.

Answer：

MacBook Air M4 weighs **1.24 kg**.

這兩句 similarity 很高，沒有問題。

但是再看：

MacBook Air M4 **does not** weigh 1.24 kg.

它和原句的 embedding similarity 通常仍然很高。

因為大部分 words 完全相同。

$$\text{sim}(E, A) \approx 0.9 + i$$

但：

$$\text{Entailment}(E, A) \approx 0$$

甚至：

$$\text{Contradiction}(E, A) \approx 1$$

這是 Semantic Similarity 最大的限制之一。近期研究也指出 embedding similarity / BERTScore 可能會被表面語意重疊欺騙，因此不宜直接當作 semantic accuracy 或 factuality。

來源：<https://aclanthology.org/2025.acl-long.632.pdf>

所以真正有價值的研究不是：

用 SBERT cosine similarity 做 RAG evaluation。

而是：

如何修改 Semantic Similarity，使它能表達 Evidence Support、Contradiction、Coverage 與 Relevance？

這就開始變成一個比較有意思的研究問題。

3. 我會把 similarity 從 scalar 改成 relation

傳統：

$$S(s_i, s_j) \in [0, 1)$$

只有：

similar / dissimilar

我們可以改成：

$$S^i(x,y)=\left[S_{semantic},P_{entail},P_{contradict},P_{neutral}\right)$$

也就是：

Semantic similarity : 0.93

Entailment : 0.08

Contradiction : 0.89

Neutral : 0.03

那麼：

Apple released the product in 2025.

和：

Apple did not release the product in 2025.

就不會再因為 cosine similarity 很高而被判斷為「good evidence」。

這也是為什麼 2025 ACL 的 Semantic-Eval 很值得你讀：它本身就是 **semantic similarity + graph weighting + NLI** 的架構，用 semantic unit pairwise similarity 建構 evaluation，再利用 NLI 降低純 similarity 的 semantic relation bias。

來源：<https://aclanthology.org/2025.acl-long.477/>

它跟我們現在想做的事情非常接近，但還不是針對 RAG diagnosis 設計的。

4. 我認為可以發展成一個「Similarity Matrix」

這可能成為整個研究的核心表示法。

假設 Answer 被拆成：

$$C=\{c_1,c_2,c_3,c_4\}$$

Retrieved Context 被拆成：

$$E=\{e_1,e_2,e_3,e_4,e_5\}$$

建立：

$$M_{ij}^{CE}=S^i(c_i,e_j)$$

得到：

Answer claim	Evidence 1	Evidence 2	Evidence 3	Evidence 4
C_1	.92	.13	.21	.09

Answer claim	Evidence 1	Evidence 2	Evidence 3	Evidence 4
C_2	.20	.96	.16	.22
C_3	.11	.17	.91	.32
C_4	.08	.14	.19	.16

很容易看到：

$C_1 \rightarrow E_1$
 $C_2 \rightarrow E_2$
 $C_3 \rightarrow E_3$
 $C_4 \rightarrow ???$

那麼：

$$C_4$$

就是 potential unsupported claim。

這已經不是單純 quality scoring，而是：

Quality Diagnosis

5. 更重要的是做第二個 Matrix

這是我認為你的想法最有潛力的地方。

把 Query 拆成 Requirement：

$$R = \{r_1, r_2, \dots, r_m\}$$

例如 Query：

比較 A 和 B 的價格、效能和耗電。

得到：

R1: A price
 R2: B price
 R3: A performance
 R4: B performance
 R5: A power consumption
 R6: B power consumption
 R7: comparative conclusion

再和 Answer claims 建立：

$$M_{ji}^{RC} = S^i(r_j, c_i)$$

例如：

Requirement	C1	C2	C3	C4
A price	.96	.11	.18	.12

Requirement	C1	C2	C3	C4
B price	.13	.93	.10	.11
Performance comparison	.17	.22	.89	.31
Power comparison	.11	.19	.21	.22

最後一行：

$$\max_i M_{4i} = 0.22$$

代表：

Query 要求 power consumption comparison，但回答沒有 cover。

因此它不是 hallucination。

而是：

Incomplete

6. 這會自然產生一套非常漂亮的 diagnosis

我們甚至可以從兩個 similarity matrices 直接推出不同品質指標。

Diagnosis	計算方向	意義
Faithfulness	Claim → Evidence	Answer 的敘述是否有根據
Completeness	Requirement → Claim	Query 要的東西是否都有回答
Relevance	Claim → Requirement	Answer 是否包含沒被問的東西
Contradiction	Evidence → Claim + NLI	是否和證據相反
Grounding	Claim ↔ Evidence	claim 是否能定位到證據

這裡出現一個非常重要的特性：

similarity 不再是 symmetric metric

傳統：

$$\text{sim}(A, B) = \text{sim}(B, A)$$

但是 quality diagnosis 必須是 directional：

$$\text{Coverage}(\text{Query}, \text{Answer}) \neq \text{Coverage}(\text{Answer}, \text{Query})$$

這跟 Precision / Recall 很像。

7. 可以借用 BERTScore 的 Precision / Recall 思想

這是我覺得很值得深入挖的一點。

BERTScore 本來就是透過 contextual embedding 做 token matching，並分別計算 precision / recall / F1。

我們可以把概念提升到 **Semantic Unit Level**。

例如 Answer Claims：

$$C = \{c_1, \dots, c_n\}$$

Query Requirements：

$$R = \{r_1, \dots, r_m\}$$

定義：

$$Recall_{requirement} = \frac{1}{m} \sum_j \max_i S(r_j, c_i)$$

它其實就是：

$$Completeness$$

而：

$$Precision_{answer} = \frac{1}{n} \sum_i \max_j S(c_i, r_j)$$

則接近：

$$Relevance$$

同樣地，Claim $\leftrightarrow$ Evidence 可以建立：

$$GroundingPrecision = \frac{1}{n} \sum_i \max_k S^i(c_i, e_k)$$

近似：

$$Faithfulness$$

所以我們其實可以建立：

Semantic Precision / Semantic Recall for RAG Quality Diagnosis

這是很值得正式研究的。

8. 甚至可以不要用 `max()`

這又有一個可以進一步研究的地方。

例如：

$$Coverage(r_i) = \max_j sim(r_i, c_j)$$

有一個潛在問題。

假設一句很 general 的回答：

兩款產品各有不同的價格、效能以及耗電表現。

可能同時：

similar(price)

similar(performance)

similar(power)

都不低。

結果模型誤以為三個 information requirements 都被回答了。

但它其實什麼具體資訊都沒提供。

因此我會考慮：

Optimal Transport

而不是單純 greedy maximum。

也就是建立：

$$M = \hat{c}$$

然後求：

$$T^{\hat{c}} = \arg \max_T \sum_{ij} T_{ij} S_{ij}$$

subject to matching constraints。

概念上：

Requirement 1 ————— Claim 2

Requirement 2 ————— Claim 5

Requirement 3 —X— no adequate claim

Requirement 4 ————— Claim 7

這樣一個 generic sentence 就不能無限制 cover 所有 requirements。

我認為這個方向甚至可能比單純 similarity 更有研究新意。

9. 再加入「方向性 Entailment」

可以把我們的 revised similarity 定義成：

$$D(x,y)=sim(x,y)\times P(entailment \mid x,y)$$

但最好再把 contradiction 分離：

$$Support(x,y)=sim(x,y)\cdot P_{entail}$$

$$Conflict(x,y)=sim(x,y)\cdot P_{contradiction}$$

例如：

Evidence:

Battery lasts 18 hours.

Claim A:

Battery life is 18 hours.

Similarity .94
Entailment .97
Support .912

但是：

Claim B:

Battery life is only 8 hours.

Similarity .86
Contradiction .95
Support .026
Conflict .817

這就把 similarity 從：

「像不像？」

改造成：

「語意上相關，而且關係究竟是 support 還是 conflict？」

2025 的 SemQA 也採用了 embedding-based semantic scoring 搭配 **bidirectional NLI entailment** 做 evidence scoring，顯示 similarity + entailment 的組合確實是一條正在發展的路線。

來源：<https://aclanthology.org/2025.fever-1.14/>

10. 為什麼不能只做 sentence-level

這點也要注意。

RefChecker 已經證明，在 hallucination detection 上，claim-triplets 比 response、sentence、sub-sentence granularity 表現更好，其 benchmark 有 11k 個人工標註 claim triplets。

來源：<https://aclanthology.org/2024.emnlp-main.395/>

所以我建議：

不要限制：

$$SentenceSimilarity$$

而把你的原始想法提升成：

$$SemanticUnitSimilarity$$

Semantic Unit 可以是：

sentence
atomic claim
claim triplet
query facet
evidence unit

研究問題反而可以變成：

Which semantic granularity produces the most reliable RAG quality diagnosis?

例如比較：

$$Sentence$$

VS

$$AtomicClaim$$

VS

$$ClaimTriplet$$

VS

$$AdaptiveSemanticUnit$$

這會是很漂亮的一個 ablation。

11. 甚至可以建立 Semantic Alignment Graph

這會直接和我們上一輪討論的 Evidence Graph 結合。

Nodes：

$$V = R \cup C \cup E$$


也就是：

Requirement
Claim
Evidence

Edge weight：

$$w_{ij} = SemanticRelation(v_i, v_j)$$

形成：



但 edge 不只是 weight：

```
{
  similarity: 0.92,
  entailment: 0.95,
  contradiction: 0.02,
  confidence: 0.91
}
```

最後 quality diagnosis 其實變成：

Graph Analysis

2025 ACL 的 Semantic-Eval 已經證明「pairwise semantic similarity + graph weighting + NLI」能有效評估 generated text，而且與 human judgments 的相關性優於傳統 n-gram 與 BERT-based metrics。

來源：<https://aclanthology.org/2025.acl-long.477/>

這代表你的構想在方法論上是有文獻支撐的，但把這套思想專門重構成 RAG 的 Requirement-Claim-Evidence 三層 **diagnosis graph**，才會是我們要尋找的 contribution。

12. 我現在反而會重新定義研究主軸

前面我們暫定：

Fine-grained Evidence-Aware Quality Estimation for Retrieval-Augmented Generation Responses

現在可以進一步變成：

Semantic Alignment-Based Fine-grained Diagnosis of Retrieval-Augmented Generation Responses

或者更完整：

Directional Semantic Alignment for Fine-grained Evidence-Aware RAG Response Quality Diagnosis

核心概念：

$$QueryRequirements \leftrightarrow AnswerClaims \leftrightarrow RetrievedEvidence$$

再融合：

$$SemanticSimilarity + Entailment + Contradiction + OptimalMatching$$

而不是依賴一個大型 LLM 直接說：

Answer quality = 4/5

13. 這會產生一個很清楚的研究假設

最核心可以直接寫成：

$$H_1:$$

A structured directional semantic-alignment metric between query requirements, answer claims, and retrieved evidence correlates more strongly with human RAG quality judgments than conventional sentence similarity or direct LLM-as-a-Judge scoring.

然後再有：

$$H_2:$$

$$Similarity + NLI > SimilarityOnly$$

$$H_3:$$

$$OptimalAlignment > GreedyMaxAlignment$$

$$H_4:$$

$$ClaimLevel > SentenceLevel$$

這四個實驗都非常清楚。

14. 而且它可能解決 LLM-as-a-Judge 的一個實務問題

ConsJudge 指出 RAG 的 LLM judge 對不同 evaluation prompts 可能產生不同判斷，prompt sensitivity 是實際問題。

來源：<https://aclanthology.org/2025.findings-acl.301/>

我們這個方法很多核心計算：

$$embedding$$

$$NLI$$

$$matrixmatching$$

graphaggregation

都是 deterministic 或接近 deterministic。

因此可能得到：

LowerEvaluationVariance

以及：

HigherReproducibility

這反而可能是很有力的論文 argument。

我目前對你的構想的判斷

可以做，而且值得往這裡收斂。

但不要把論文定位成：

「使用 sentence similarity 評估 RAG answer。」

因為這太容易被 reviewer 質疑：「embedding similarity 已經存在很久了。」

真正應該研究的是：

TraditionalSentenceSimilarity → DirectionalSemanticAlignment

然後：

SemanticAlignment+NLI+SemanticUnitDecomposition+OptimalMatching

形成：

Requirement ↔ Claim ↔ Evidence

的 **RAG Quality Diagnosis Framework**。

這樣你原本「sentence similarity 是否可以修改後應用到 RAG diagnosis」的觀察，就從一個小技巧升級成了一個相當完整的研究方向。

我下一步會建議直接研究這個問題：**SBERT / BERTScore / Cross-Encoder / NLI / Optimal Transport 各自在這個 Requirement–Claim–Evidence alignment 裡應該扮演什麼角色**。如果把這一層定清楚，我們幾乎就可以開始畫正式模型架構與設計第一版實驗了。

Turn 5 — User

基於目前學界的風向，如何利用 LLMs + modifications of conventional similarity algorithms

Assistant (進度更新)

可以。若以 2025–2026 學界風向來看，最有潛力的不是「讓 LLM 取代 similarity」，而是讓 **LLM 負責語意結構化與推理**，傳統 **similarity 負責穩定、可重現、低成本的對齊與量化**。我會特別看目前學界是否正在往「LLM + NLI + optimal transport / graph alignment / learned similarity」這種 hybrid evaluator 收斂。

Assistant

可以，而且從 2025–2026 的論文趨勢來看，你現在這個想法其實比「直接做一個 LLM-as-a-Judge」更符合一條正在變強的研究路線：

LLM for semantic structuring/reasoning + modified classical similarity for measurement

也就是 **LLM 不直接決定分數，而是負責把自然語言轉換成較可靠的 semantic units**；**Similarity/NLI/Optimal Matching** 再負責可重現的量化。

2025 EMNLP 的 Co-Eval 就已經明確朝這個方向走：用 LLM 做 criteria planning，再結合 optimized machine metrics；作者報告這種 hybrid 方法能降低 LLM judge bias，並提高與 human preference 的 Spearman correlation。ACL 2025 的 Semantic-Eval 也走「semantic similarity + graph weighting + NLI」而非單純 LLM judge。

來源：<https://aclanthology.org/2025.emnlp-main.1307/>

我認為目前最值得走的研究架構

可以把整套方法想成：

$LLM \rightarrow SemanticRepresentation \rightarrow ModifiedSimilarity \rightarrow StructuredAlignment \rightarrow Quality$

而不是：

$$LLM(Query, Context, Answer) \rightarrow 4.2/5$$

這個差別非常重要。

第一層：LLM 不負責評分，而負責「Semantic Decomposition」

輸入 RAG 三個東西：

$Q = \text{Query}$

$A = \text{Answer}$

$E = \text{Retrieved Evidence}$

讓 LLM 轉換成三種 semantic units。

Query：

$$Q \rightarrow R = \{r_1, r_2, \dots, r_m\}$$

也就是 information requirements 。

Answer :

$$A \rightarrow C = \{c_1, c_2, \dots, c_n\}$$

也就是 atomic claims 。

Evidence :

$$E \rightarrow F = \{f_1, f_2, \dots, f_k\}$$

也就是 evidence facts 。

最後問題變成：

Query Requirements

↓

r1 r2 r3 r4

↓

Answer Claims

c1 c2 c3 c4 c5

↓

Evidence Facts

f1 f2 f3 f4 f5 f6

這是 LLM 最適合扮演的角色 。

因為 LLM 很擅長：

- decomposition
- semantic normalization
- decontextualization
- coreference resolution
- information need extraction

但不一定適合直接當一個穩定的 scalar scorer 。

ACL 2025 也發現 claim decomposition 本身會直接影響 downstream verifier，因此提出 dynamic decomposition，讓 decomposition policy 配合 verifier，而不是把拆 claim 當成固定前處理。

來源：<https://aclanthology.org/2025.acl-long.254/>

第二層：把傳統 cosine similarity 改成「Multi-channel Similarity」

這裡我認為是你最可能做出方法 contribution 的地方。

傳統：

$$S(x, y) = \cos(e_x, e_y)$$

太簡單。

我們可以變成：

$$S^i(x, y) = f(S_{emb}, S_{cross}, P_{ent}, P_{con}, S_{entity}, S_{number})$$

例如：

$$S_{emb} = \cos(E(x), E(y))$$

代表 general semantic similarity。

Cross-encoder：

$$S_{cross} = C E(x, y)$$

負責 finer interaction。

NLI：

$$P_{ent} = P(y \text{ entails } x)$$

$$P_{con} = P(y \text{ contradicts } x)$$

再加入：

$$S_{entity}$$

entity consistency，

以及：

$$S_{number}$$

numeric consistency。

因此 similarity 不再只是一個 embedding cosine。

一個很實際的公式

可以先從：

$$S_{support}(c, e) = \alpha S_{cos} + \beta S_{cross} + \gamma P_{ent} - \delta P_{contra}$$

開始。

再加入：

$$- \lambda_e \text{EntityMismatch}$$

$$- \lambda_n \text{NumericMismatch}$$

形成：

$$S_{support}(c, e) = \alpha S_{cos} + \beta S_{cross} + \gamma P_{ent} - \delta P_{contra} - \lambda_e M_e - \lambda_n M_n$$

這樣：

Revenue increased from 10M to 20M.

和：

Revenue decreased from 10M to 20M.

即使：

$$CosSim \approx 0.95$$

也不會得到高 support score。

第三層：Similarity 應該變成 directional

這會是我非常推薦你研究的一點。

傳統 similarity：

$$sim(x, y) = sim(y, x)$$

但 RAG quality 根本不是 symmetric problem。

例如：

$$Coverage(Query, Answer)$$

跟：

$$Relevance(Answer, Query)$$

不是同一件事情。

因此可以建立：

$$S_{R \rightarrow C}$$

表示：

Query requirement 是否被 Answer cover？

以及：

$$S_{C \rightarrow E}$$

表示：

Answer claim 是否被 evidence support？

這讓我們得到兩種 completely different diagnostics。

Requirement → Claim

建立：

$$M_{ij}^{RC} = S^i(r_i, c_j)$$

如果：

$$\max_j M_{ij}^{RC} \ll 1$$

代表 requirement r_i 沒被回答：

MissingInformation

Claim → Evidence

建立：

$$M_{jk}^{CE} = S^i(c_j, e_k)$$

如果：

$$\max_k M_{jk}^{CE} \ll 1$$

表示：

UnsupportedClaim

如果：

$$P_{contra} \gg P_{ent}$$

表示：

ContradictedClaim

這就從 similarity 變成真正的 **diagnostic mechanism**。

第四層：修改 BERTScore 的 Precision / Recall 思路

我覺得這可能是非常漂亮的一條研究線。

BERTScore 原本做：

Precision

Recall

F1

我們可以把 token-level matching 升級成：

Semantic Unit Matching

例如 Query requirement recall：

$$R_Q = \frac{\sum_i w_i \max_j S(r_i, c_j)}{\sum_i w_i}$$

這其實就是：

Completeness

而 Answer precision：

$$P_A = \frac{\sum_j v_j \max_i S(c_j, r_i)}{\sum_j v_j}$$

接近：

Relevance

再做 Claim→Evidence：

$$P_E = \frac{\sum_j v_j \max_k S_{support}(c_j, e_k)}{\sum_j v_j}$$

就接近：

Faithfulness

因此可以建立一個：

RAG Semantic Precision / Recall / Grounding

這比直接平均 cosine similarity 有意思很多。

第五層：把 `max()` 改成 Optimal Matching

我認為這可能是你方法中最值得嘗試的 modification。

目前很多 metric 寫成：

$$score(r_i) = \max_j sim(r_i, c_j)$$

問題是同一句 vague sentence 可以同時 match 很多 requirements。

例如：

A 與 B 在價格、效能、重量方面都有差異。

它可能同時對：

price
performance
weight

有不低的 similarity。

但是它實際上沒有回答任何細節。

因此我會改成 **Bipartite Matching / Optimal Transport**。

建立：

$$S = \mathcal{I}$$

再求：

$$T^{\mathcal{I}} = \arg \max_T \sum_{ij} T_{ij} S_{ij}$$

subject to semantic mass constraints。

可以使用：

- Earth Mover's Distance
- Sinkhorn distance
- Hungarian matching
- Partial Optimal Transport

如此：

R1 ——— C3
R2 ——— C1
R3 —X— missing
R4 ——— C5

就比：

$$\max similarity$$

更能描述 coverage。

第六層：讓 LLM 幫 similarity 做「semantic augmentation」

這是另一個很符合現在研究風向的方法。

2025 的 GenEOL 顯示，LLM 可以先產生多個 **meaning-preserving transformations**，再 aggregate embeddings；在 STS benchmark 上，比既有 training-free sentence embedding 方法平均提高 2.85 points。

來源：<https://aclanthology.org/2025.findings-naacl.122/>

這提供一個很好的思路。

例如 claim：

The company posted revenue of \$12M in Q2.

LLM 先產生：

The firm's Q2 revenue was \$12 million.

Revenue reached twelve million dollars during Q2.

The company earned \$12M in revenue in the second quarter.

得到：

$$e_1, e_2, e_3, e_4$$

再：

$$E(c) = \text{Aggregate}(e_1, e_2, e_3, e_4)$$

而不是單一 embedding。

因此：

$$\text{sim}(c, e)$$

可以改成：

$$\text{sim}_{\text{multi-view}}(c, e)$$

這可能提高 paraphrase robustness。

第七層：加入 Hard Negative generation

這也是 LLM 很適合做的事情。

不是只生成 paraphrase。

LLM 還可以生成：

Semantic positive

Sales increased by 20%.

→

Sales grew by one fifth.

Hard contradiction

Sales decreased by 20%.

Entity corruption

Company B' s sales increased by 20%.

Numeric corruption

Sales increased by 30%.

Temporal corruption

Sales increased by 20% in 2023.

vs evidence :

這些是 conventional embeddings 最容易出錯的地方。

然後利用：

Positive, Hard Negative

做 contrastive learning。

可以學：

$$S_{\theta}(x, y)$$

讓 similarity 空間專門適應：

RAG Evidence Alignment

而不是 general STS。

2025 EMNLP 的 Sentence Smith 就使用 semantic graph manipulation 與 entailment checking 產生 hard-negative text pairs，專門測試 embedding models 的弱點，這與這條思路非常吻合。

來源：<https://aclanthology.org/2025.emnlp-main.1343/>


第八層：LLM 最後只處理「難例」

我非常不建議：

100 %

cases 都送大型 LLM judge。

比較合理的是 cascade。



例如：

$$confidence>0.9$$

直接接受 similarity/NLI。

如果：

$$0.4<confidence<0.6$$

才送 LLM reasoning。

這樣同時有：

- lower cost
 - lower stochasticity
 - higher reproducibility
 - LLM reasoning capability
-

這其實符合 2026 的明顯研究走向

今年 SemEval 已經出現很典型的 hybrid architecture：

$$LLM+CrossEncoder+SemanticSimilarity+NLI$$

例如 SemEval 2026 Task 5 的系統將 fine-tuned Llama-3 8B 和雙向 DeBERTa cross-encoder 結合，cross-encoder 同時針對 semantic similarity 與 NLI 最佳化。

來源：<https://aclanthology.org/2026.semeval-1.115/>

另外 SemEval 2026 的 narrative similarity 任務也顯示，純 dense embedding similarity 不足以處理深層結構語意；structured LLM prompting 加上 heterogeneous ensemble 能明顯改善表現。

來源：<https://aclanthology.org/2026.semeval-1.271/>

所以學界現在不是：

$$Embedding vs LLM$$

而愈來愈像：

$$Embedding+discriminativemodels+LLM$$

對你的研究，我會選這個組合

Component	技術	功能
Semantic structuring	LLM	Requirement / Claim / Evidence decomposition
Coarse semantic match	Bi-encoder cosine	快速候選對齊
Fine semantic match	Cross-encoder	精細 relevance

Component	技術	功能
Logical relation	NLI	entail / contradict / neutral
Exact-sensitive match	entity / numeric rules	防止數字與 entity 錯配
Alignment	Optimal Transport / Hungarian	global semantic matching
Aggregation	Graph / learned regression	quality dimensions
Difficult cases	LLM reasoner	ambiguous verification
Calibration	temperature / isotonic / conformal	confidence

這就是我現在最推薦的 architecture 。

一個可能很有論文味道的核心公式

最後可以定義：

$$z_{ij} = [CosSim_{ij}, CrossEnc_{ij}, Entail_{ij}, Contra_{ij}, Entity_{ij}, Numeric_{ij}]$$

再讓：

$$S_{ij} = g_{\theta}(z_{ij})$$

其中 g_{θ} 可以只是很小的：

- logistic regression
- MLP
- ranking model

不需要又放一個大型 LLM 。

再做：

$$T^{\hat{L}} = OT(S, W_R, W_C)$$

其中：

- W_R ：LLM 判斷的 requirement importance
- W_C ：claim importance

最後：

$$Completeness = f(T_{RC})$$

$$Faithfulness = f(T_{CE})$$

$$Relevance = f(T_{CR})$$

$$Contradiction = f(P_{contra})$$

因此最後不是：

```
{  
  "quality": 0.82  
}
```

而是：

```
{  
  "quality": 0.82,  
  "faithfulness": 0.91,  
  "completeness": 0.73,  
  "relevance": 0.92,  
  "contradiction": 0.04,  
  "unsupported_claims": ["C4"],  
  "missing_requirements": ["R3"],  
  "confidence": 0.89  
}
```

最關鍵的一個研究定位

我現在會避免把你的研究稱為：

LLM + Sentence Similarity

因為 reviewer 很容易覺得只是把兩個已有方法接起來。

更好的 conceptual framing 是：

LLM-guided Structured Semantic Alignment for RAG Quality Diagnosis

其中 LLM 是：

SemanticStructureGenerator

傳統 similarity algorithms 則從：

CosineSimilarity

升級成：

Directional+Relation-aware+Importance-weighted+Globally-matched+CalibratedSem

這個 framing 比「修改 cosine similarity」強很多。

而且有一個很好的時機點：2025 的研究開始明確暴露純 LLM judge 的問題，例如對能力接近的系統，LLM evaluator 與 human judgment 的 correlation 會顯著下降；另一方面 Co-Eval、Semantic-Eval、2026 SemEval systems 都在證明 **hybrid evaluator** 是值得研究的方向。

來源：<https://aclanthology.org/2025.findings-emnlp.1036/>

如果以「**有沒有機會形成一篇 ACL/EMNLP paper**」來看，我目前最看好的技術主軸會是：

LLMSemanticDecomposition+Multi-channelSimilarity+OptimalTransport+NLI+Uncer

其中真正值得深入推導、做 ablation 的核心，很可能是 **Multi-channel Similarity + Optimal Transport**。這會讓你的方法不只是另一個 prompt-based evaluator，而是一個有明確數學結構的 RAG diagnosis framework。

Turn 6 — User

另一個主題則是，chat content ground truth measurement

Assistant (進度更新)

這個題目和前面的 RAG quality diagnosis 很接近，但核心不同：**RAG 是「回答有沒有被給定 evidence 支持」；chat content ground truth measurement 則更像「對話中的陳述，能不能被外部世界的可靠事實驗證」**。我會把它整理成「如何定義 ground truth、如何量化 factual correctness、以及如何處理時間性、來源衝突與無法驗證陳述」三個層次。

Assistant

可以，而且我認為這個題目甚至可以和前面的 **RAG Quality Diagnosis** 分成兩條互補的研究線。

不過我會先修正一個學術上的用詞：**「Chat Content Ground Truth Measurement」最好不要直接把 ground truth 當成「一句話是不是真」**。因為聊天內容裡有很多陳述根本不存在唯一 ground truth，例如意見、建議、使用者自身經驗、預測。VeriScore 就特別指出，長文本 factuality evaluation 的一個核心問題，是必須先區分 **verifiable 與 unverifiable claims**。

來源：<https://aclanthology.org/2024.findings-emnlp.552/>

我比較建議把研究名稱定成：

Fine-grained Ground Truth and Factuality Measurement for Multi-turn Conversations

或更有研究味道：

Evidence-, Context-, and Time-Aware Factuality Measurement for Multi-turn LLM Conversations

一、Chat 的「Ground Truth」其實至少有三種

這點我認為會變成這個研究最重要的 conceptual contribution。

假設有對話：

User：我的公司在台北，我們公司去年營收 3 億。

Assistant：所以你的公司去年營收是 3 億。

Assistant：台灣 2025 年 GDP 成長率是 X%。

Assistant：我認為明年的景氣可能比較好。

這三種陳述其實完全不同。

我會定義：

$$\text{Grounding}(c) = \{\text{Contextual}, \text{External}, \text{Temporal}, \text{Unverifiable}\}$$

類型	Ground Truth 從哪來？	例子
Conversation Ground Truth	對話歷史	使用者說「我的公司去年營收 3 億」
External Ground Truth	外部可靠來源	某國 GDP、公司 CEO
Temporal Ground Truth	某個時間點的外部來源	「現在的 CEO 是誰」
Non-verifiable	沒有唯一 ground truth	意見、預測、偏好

因此第一個非常重要的原則是：

Note every chat statement has an external ground truth

二、這和 RAG Groundedness 有本質差異

前面我們研究的 RAG 是：

Query + Retrieved Evidence + Answer

因此 evidence 已經存在。

要判斷的是：

Answer Claim ↔ Retrieved Evidence

這是一個相對 **closed-world** 的問題。

但一般 Chat：

Conversation → Claim

沒有預先給定 evidence。

因此需要：

Claim → Evidence Search → Source Selection → Verification

它其實變成：

Open World Factuality Measurement

這就是 SAFE 的核心思想之一：先把長回答拆成個別 facts，再透過搜尋取得證據，逐一判斷 support。SAFE 在約 16k 個 individual facts 上，與 crowdsourced annotators 的一致率約為 72%。

來源：<https://deepmind.google/research/publications/85420/>

三、但 Multi-turn Chat 比 SAFE 更複雜

SAFE / FActScore 主要研究：

Single Response

而聊天是：

$$H_t = \{U_1, A_1, U_2, A_2, \dots, U_t, A_t\}$$

後面的陳述可能依賴前面的內容。

例如：

User：台積電董事長是誰？

Assistant 回答 A。

幾輪之後：

User：他是哪一年接任的？

這時候：

「他」

必須先 resolve 到 conversation entity。

所以：

$$GroundTruth(c_t)$$

實際上是：

$$G(c_t \mid H_{1:t}, Time, ExternalEvidence)$$

而不是：

$$G(c_t)$$

這也是目前 multi-turn evaluation 越來越受重視的原因。例如 ChatBench 發現，單純 AI-alone benchmark accuracy 並不能可靠預測實際 user-AI conversation accuracy。

來源：<https://aclanthology.org/2025.acl-long.1262/>

MultiChallenge 也顯示，multi-turn conversation 同時需要 context allocation、instruction following 和 in-context reasoning，而當時的 frontier models 在該 benchmark 上仍有明顯困難。

來源：<https://aclanthology.org/2025.findings-acl.958/>

四、我認為你的研究可以從「Claim」開始

整段 conversation：

$$D = \{T_1, T_2, \dots, T_n\}$$

Assistant turns：

$$A = \{A_1, \dots, A_k\}$$

先透過 LLM：

$$A_i \rightarrow \{c_{i1}, c_{i2}, \dots, c_{im}\}$$

也就是 atomic claims。

這和 FActScore 的思想一致：不要整段回答只打一個 factuality score，而是拆成 atomic facts，再計算多少 facts 能被可靠知識來源支持。

來源：<https://aclanthology.org/2023.emnlp-main.741/>

五、但 Chat 必須多做一個「Claim Type Classification」

這是我認為可以和現有 factuality work 拉開距離的地方。

每個 Claim 先分類：

$$Type(c_i)$$

例如：

EXTERNAL_FACT
CONVERSATIONAL_FACT
TEMPORAL_FACT
INFERENCE
OPINION
PREDICTION
PERSONAL_CLAIM

例如：

「你剛剛說你今年 48 歲。」

這不應該拿去 Wikipedia 搜尋。

它應該驗證：

$$c_i \leftrightarrow ConversationHistory$$

而：

「台灣人口約多少？」

應該：

$$c_i \leftrightarrow ExternalEvidence$$

這個 routing 我認為非常重要。

六、我會做成四層 Ground Truth

Layer 1 — Conversation Grounding

判斷：

Claim ↔ ConversationHistory

例如：

User:

我的預算是 5 萬。

Assistant later:

你的預算大約是 10 萬。

外部世界根本無法判斷。

但是 conversation ground truth：

Contradiction

非常明確。

Layer 2 — External Factuality

例如：

日本首都是東京。

進行：

Claim → Search → Evidence

得到：

Support

FActScore / SAFE 就屬於這個 family。

來源：<https://aclanthology.org/2023.emnlp-main.741/>

Layer 3 — Temporal Factuality

這會是這個題目非常重要的一塊。

例如：

「OpenAI 的 CEO 是誰？」

這不是：

Truth

而是：

$Truth(t)$

因此 claim 應該表示成：

$c=(subject, predicate, object, time)$

例如：

$(Company, CEO, X, 2026-09-22)$

2026 EACL 的研究已經明確指出 factuality benchmark 會「老化」：現實世界改變後，靜態 ground truth 可能反而讓正確的新答案被判錯，因此需要 up-to-date fact retrieval。

來源：<https://aclanthology.org/2026.eacl-short.37/>

FreshQA 更是直接持續更新資料來處理這個問題。

來源：<https://github.com/freshllms/freshqa>

所以我認為：

TemporalGroundTruth

會是這個研究最值得強調的方向之一。

七、Layer 4 — Source Reliability

這又比我們之前的 RAG 問題再多一層。

假設 Claim：

某種藥物可以治療疾病 X。

找到兩篇 evidence：

random-blog.com

official-health-authority.gov

兩個都可能 semantic similarity 很高。

但：

$Reliability(E_1) \neq Reliability(E_2)$

因此不能只有：

EvidenceSupport

還必須有：

Source Reliability

2025 的 misinformation evaluation 研究已經開始把 factuality 與 source reliability 分開建模，而不是只做 binary fact checking。

來源：<https://aclanthology.org/2025.emnlp-main.764/>

所以：

Ground Truth Score

應該考慮：

$$ClaimEvidenceAgreement \times EvidenceReliability$$

八、這剛好又可以和你前面的 Similarity 想法結合

我們前面討論：

$$SemanticSimilarity + NLI + LLM$$

這裡完全適用。

但要注意：

Similarity 只負責找 Evidence

$$Claim \xrightarrow{Similarity} CandidateEvidence$$

不能直接：

$$Similarity = 0.95 \Rightarrow True$$

例如：

2025 GDP increased 5%.

和：

2025 GDP decreased 5%.

embedding similarity 很可能極高。

所以第二階段：

$$Claim + Evidence \rightarrow NLI$$

得到：

$$P_{entail}$$

$$P_{contradict}$$

$$P_{insufficient}$$

九、可以定義一個 Multi-dimensional Ground Truth Vector

這比單一分數更合理。

對 claim c_i :

$$GT(c_i) = [E_i, C_i, T_i, R_i, V_i, U_i]$$

其中：

$E_i = EvidenceSupport$

$C_i = ConversationConsistency$

$T_i = TemporalValidity$

$R_i = SourceReliability$

$V_i = Verifiability$

$U_i = Uncertainty$

例如：

```
{  
  "claim": "Company X's CEO is John Smith",  
  "claim_type": "TEMPORAL_FACT",  
  
  "evidence_support": 0.92,  
  "conversation_consistency": 1.0,  
  "temporal_validity": 0.96,  
  "source_reliability": 0.98,  
  
  "verdict": "SUPPORTED",  
  "confidence": 0.93  
}
```

這會比：

```
{"truth": true}
```

成熟很多。

十、而 Conversation Level Score 可以這樣設計

假設一段 chat 有 N 個 verifiable claims：

$$C = \{c_1, \dots, c_N\}$$

不能單純平均。

可以使用 importance weighting :

$$Factuality(D)=\frac{\sum_i w_i GT(c_i)}{\sum_i w_i}$$

其中 :

$$w_i=ClaimImportance(c_i)$$

例如 :

「產品顏色是深灰」

錯了 ,

和 :

「這個藥物劑量是 500mg」

錯了 ,

不應該具有相同 weight 。

十一、我反而認為可以建立一個「Ground Truth Graph」

這和我們上一個研究可以共享方法論。


Nodes :


- Conversation Claim
- Conversation Evidence
- External Evidence
- Entity
- Timestamp
- Source

Edges :

- supports
- contradicts
- refers_to
- derived_from
- valid_at

形成 :





然後 ground truth measurement 其實變成：

EvidenceGraphReasoning

十二、這個題目真正有意思的研究問題

我會先定這五個 RQ：

RQ1

Can factuality of multi-turn conversations be measured more accurately by jointly modeling conversational and external evidence?

RQ2

Does claim-type-aware evidence routing outperform universal web-based verification?

也就是：

personal/context claim → chat history

external fact → web

temporal fact → fresh web

vs 所有東西都 search。

RQ3

How much does temporal evidence affect factuality judgments in real-world conversations?

這很符合 2026 的 research trend。

來源：<https://aclanthology.org/2026.eacl-short.37/>

RQ4


Can source reliability improve claim verification beyond semantic entailment alone?

RQ5


Can hybrid similarity + NLI + LLM reasoning produce more stable factuality measurements than direct LLM-as-a-Judge?

這就能和你另一條研究線共享大量技術。

十三、我會把 architecture 畫成這樣



再：



十四、這個研究和 RAG Quality Diagnosis 可以共用 70% 技術

其實這是很漂亮的地方。

共同核心：

ClaimDecomposition
SemanticSimilarity
EvidenceRetrieval
NLI
OptimalMatching
ConfidenceCalibration

但兩個 problem formulation 不一樣：

RAG Quality Diagnosis	Chat Ground Truth Measurement
evidence 已給定	evidence 必須搜尋
closed-world	open-world
評 Answer quality	評 factual truth
Context = retrieved docs	Context = conversation + world
emphasis : coverage	emphasis : verification
temporal 可選	temporal 很重要
source reliability 次要	source reliability 核心

所以它們不是兩篇重複研究。

十五、我認為這個题目的真正亮點

如果只叫：

Chat Factuality Evaluation

其實已有相當多工作。

真正可以形成你的研究特色的是：

ConversationGrounding+ExternalGrounding+TemporalGrounding+SourceReliability

再透過：

LLM-guidedClaimDecomposition+ModifiedSemanticSimilarity+NLI+EvidenceGraph

完成 **fine-grained truth diagnosis**。

我甚至會暫時給它一個名字：

ChatGT: Context-, Evidence-, and Time-Aware Ground Truth Measurement for Multi-turn Conversations

這個方向和前面的 RAG 題目可以形成一個很漂亮的研究系列：

RAGQE:「這個 RAG 回答好不」

以及：

ChatGT:「這段 Chat 裡哪一些」

後者的難度其實更高，但研究空間也更大。特別是 **conversation-local truth** 與 **external world truth** 的區分，以及 **temporal ground truth**，我認為很值得繼續往下挖。

Turn 7 — User

你可以把這個對話的完整內容匯出成 pdf 嗎？